为什么学人工智能伦理与安全要先看政策法规

边界、责任与坐标：政策法规在课程中的位置

课程	讲次	主题
人工智能伦理与安全	导论 · 第一讲	政策法规的先在性

目录 —— 本讲结构

五条理由，一条主线

01	问题的提出	伦理讲判断，安全讲风险，政策讲条款——三者不在一个层面
02	边界图，不是禁令清单	政策回答三个问题：哪里不能去、哪里可以去、可以走多远
03	了解限制，才能放开手脚	规则越清楚，可动作的范围越确定
04	原则落到具体责任	义务如何配置，决定责任归谁
05	判断新文件的参照系	两个维度构成坐标，定位之后只需两个问句
06	底线，不是全部	合规解决底线问题，不解决取舍问题

三个层面，不在同一条线上

讲人工智能伦理与安全，通常从政策法规讲起。这一安排常被质疑：政策文件冗长、更新频繁、条款细碎，与教师的日常备课上课隔着一段距离。

层面	它讲的是什么	与日常教学的距离
伦理	判断	抽象原则，需要具体情形才能落地
安全	技术风险	需要技术背景，未必对应课堂决策
政策法规	文件条款	条文细碎，更新频繁，看似最远

疑 问　先讲政策，是遵循惯例，还是为了给后续内容找一个权威依据?

这个问题必须正面回答

回答不成立，后面的内容就只是知识罗列；回答成立，整门课的讲授顺序才有依据。

回答不成立

先讲政策只是惯例。后续各讲之间缺少共同前提，伦理、安全、政策各自成章，合起来仍是一份材料汇编。

回答成立

政策构成共同前提。伦理判断有对象，安全措施有指向，各讲之间的先后顺序可以被论证，而不是被安排。

三条理由分别对应三个层面的问题：政策写的是什么（边界）、限制与使用是什么关系（自由）、原则如何落到人头上（责任）。

一句话　了解限制，是为了获得自由。

政策回答的是三个问题

多数人以为政策就是一张禁令清单，记住的是不许做什么。实际不是。政策划定的是范围，回答的是三个问题。

问 题 一

哪里不能去

明确的禁区，越界即违规

问 题 二

哪里可以去

被允许的空间，通常写得比禁区更细

问 题 三

可以走多远

程度的限定：条件、程序、留痕要求

禁令清单的理解

记住的是不许做什么。清单之外的部分没有信息，遇事只能靠猜。

边界图的理解

记住的是范围与程度。清单之外仍有判断依据，遇事可以定位。

实 质 政策给出的不是“允许或禁止”，而是“范围与程度”。

一种情形，两种理解，两种结果

情形	只看禁令	看了边界
学生作文用 AI 辅助修改，可不可以?	想不出答案，索性不用。学生失去一次练习机会，教师也说不清理由。	可以用。修改痕迹要保留；最终评价不直接采用工具结果。同一件事，从“不敢做”变成“知道怎么做”。

禁令式理解的成本不在禁止本身，而在于**清单没有覆盖的情形里，人没有判断依据**。边界式理解给出的是一组条件，条件满足即可行动，条件不满足则调整做法，而不是放弃做法。

对教师而言

同一个工具，在两种理解下相差的不是胆量，而是可操作的程序：留痕怎么做、评价怎么定、什么环节由人决定。

结 论 边界清楚，问题就从“能不能用”变成“怎样用才合规”。

不清楚边界，损失有两个方向

对老师来说，边界是否清楚，直接体现为可用空间的大小。

其一 · 少用或不用

稳妥的做法是回避。而在工具已经进入日常工作的环境里，回避等于让渡效率：备课、命题、批改、材料整理，逐一退回手工。

其二 · 不知边界而越界

把整张成绩表上传，把生成内容原样提交，事后才知道问题在哪。损失发生在事后，且往往无法回退。

- 两种损失方向相反：一种损失效率，一种损失安全。
- 来源相同：都不清楚限制的位置。

判断 回避与越界不是两种态度，而是同一个知识缺口的两个出口。

规则越清楚，可动作的范围越确定

限制与自由不是此消彼长的关系。规则模糊时，人只能按最保守的方式行事，实际可用的余地反而更小。

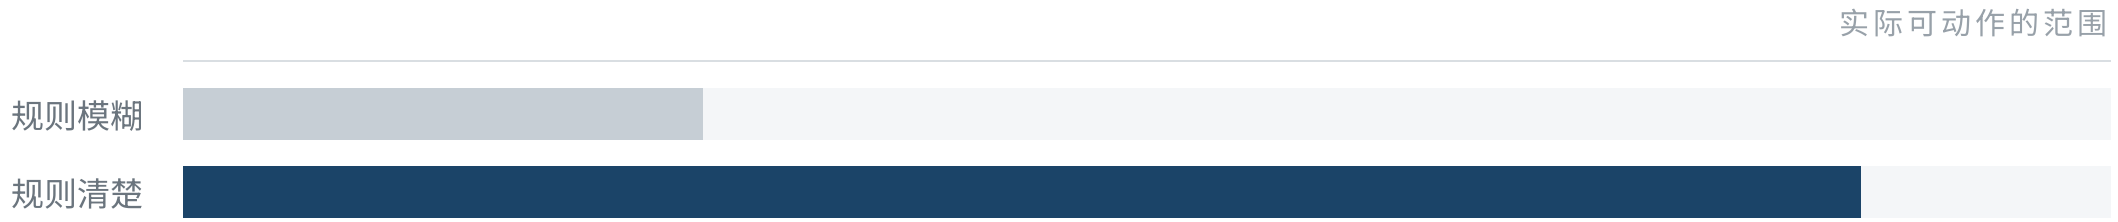


图 1　同一尺度下，模糊规则使人只取最保守的一段；规则明确后，可确认的区间更长。

人在不确定的环境里不会冒险试探，只会选择最不容易出错的做法。于是模糊的规则并不产生更多自由，它产生的是普遍的保守。规则写清楚之后，动作的边界可以被确认，人才敢把可用的部分用足。

结 论　规范的目的不是禁止，而是把可动作的范围确定下来。

政策文本自己就是这么写的

> 《生成式人工智能服务管理暂行办法》· 第一条 · 立法目的
>
> 促进健康发展，规范应用。

> 《生成式人工智能服务管理暂行办法》· 第三条 · 基本原则
>
> 发展和安全并重，实行包容审慎和分类分级监管。

发展与安全并重写在总则里，而不是写在罚则里。总则规定的是整部文件的取向：规范服务于发展，监管采取包容审慎、分类分级的方式，而非一律从严。

读法

先读第一条与总则，再读义务条款。前者说明文件要解决什么问题，后者说明由谁、在什么环节、做到什么程度；两条合起来，才看得出这份文件的性质。

判断 规范的目的不是禁止，这一点由文件自己声明。

教师规范把大量篇幅花在说明怎么用上

文件	要点
名称	《教师生成式人工智能应用指引（第一版）》
发布	2025 年 11 月，国家层面首份专门面向教师的生成式人工智能规范
取向	不是禁止，而是引导教师**愿用、会用、善用**
结构	六个维度；大量场景示例说明可以怎么用；另以行为示例划定不能做的边界

一份教师规范，把主要篇幅用于说明如何使用，只在必要时用行为示例标出边界。这个篇幅分配本身就是判断依据：文件要解决的主要问题是“不会用、不敢用”，而不是“用多了”。

推 论 规范的重量放在引导上，说明限制的位置是为使用划界，不是为使用设障。

把原则转成可执行的语言

公平、透明、可问责这些伦理原则，单独说时人人都同意，落到具体情形却难以判断。政策的作用，是把原则翻译成可以履行的义务。

要 素 一

谁承担义务

责任主体是谁：提供者、使用者、还是监管者

要 素 二

承担到什么程度

义务的强度：做到即可，还是必须证明做到

要 素 三

在哪个环节履行

义务的时点：上线前、运行中、还是事后可追溯

三个要素一旦确定，原则就不再是态度问题，而是可以检查的事实问题：谁做了、做到没有、在哪个环节做的。这也是伦理讨论能够进入教学管理的前提。

结 论 原则提供方向，政策提供落点；没有落点的原则，只能停留在表态。

义务主要落在平台，使用者承担剩余义务

表 1　义务配置的基本分工

主体	主要义务	配置理由
服务提供者	备案、标识、内容审核	平台有技术能力履行，个体没有；义务配置给平台，监管链条最短
使用者	剩余义务	数量少，但性质是法定的，不因不知情而免除

知道义务主要落在平台

就不会把工具出错的责任全揽在自己身上。使用合规的工具、按说明使用，已经履行了使用者一侧的义务。

知道剩余义务不可免除

就不会把生成内容原样转发。不知情不构成免责理由，核对与判断仍在使用者一侧。

结 论　责任边界清楚了，才敢用；边界不清，用与不用都在承担风险。

需要的能力不是记住条款

人工智能的技术形态还在分化，规范文件持续出台。逐份跟踪不现实，读完的很快过期。

低效的做法

逐份跟踪、逐条记忆。文件数量在增加，记忆的边际收益在下降；等到需要判断时，记住的那一份往往已经修订。

有效的能力

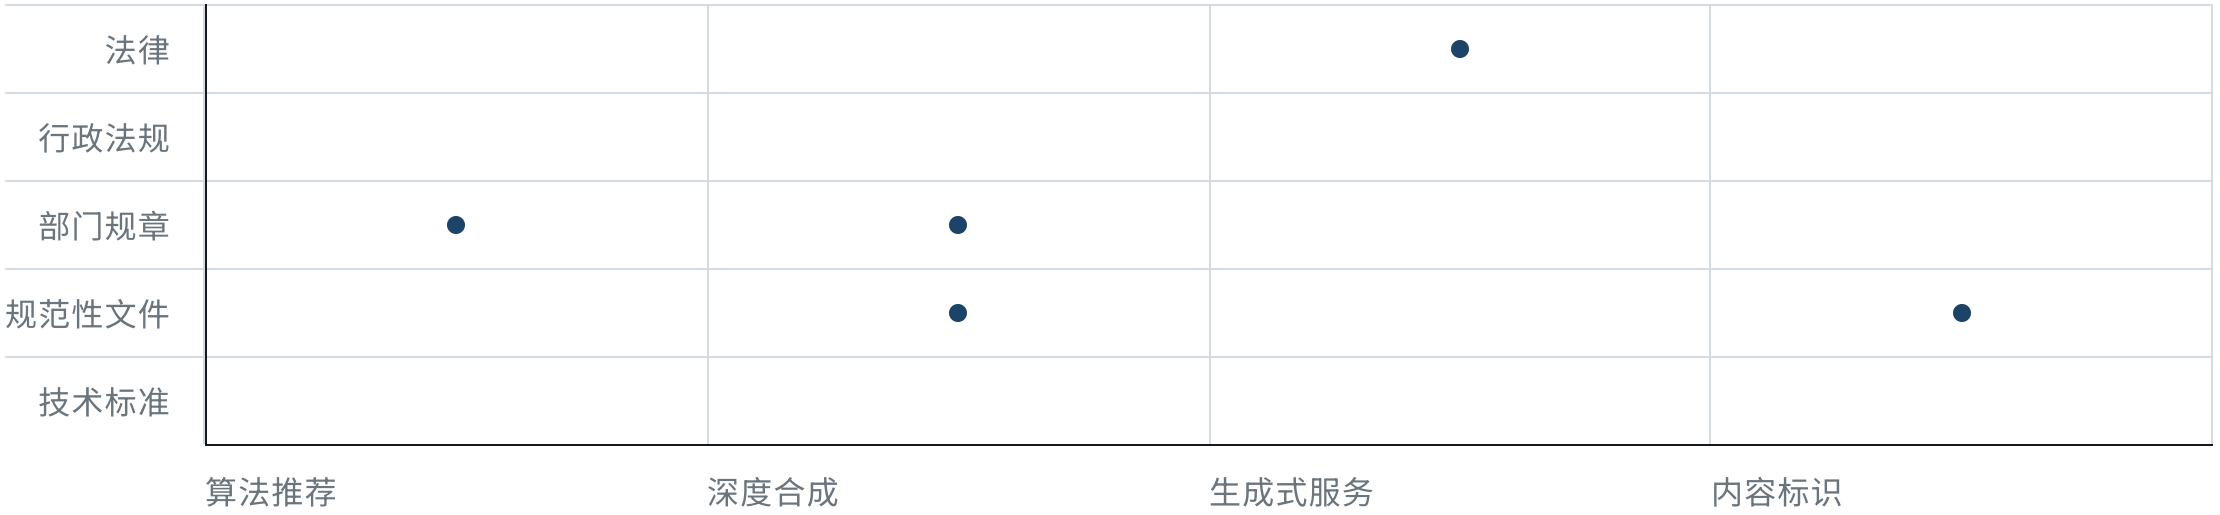
一份没见过的文件出现时，能判断它管的是什么、管到多硬。判断依据不是内容记忆，而是结构认知。

结构认知的两个维度

现行文件按效力层级划分，决定“管到多硬”；按规制对象划分，决定“管的是什么”。两个维度交叉，构成一个坐标，任何一份新文件都能在其中定位。

结 论 掌握坐标，比掌握条款更耐用。

两个维度构成一个坐标



纵轴：效力层级，决定约束强度与违反后果。

横轴：规制对象，决定适用范围与技术环节。

图 2　政策文件的定位坐标（示意，点为现行主要文件的大致分布）

用 法　定位之后只需两个问句：它管哪一种技术形态，义务主要配置给谁。

一份新规，两分钟定位

举例：一份关于 AI 生成内容标识的新规出台。不必等培训解读，用坐标自己判断。

问句	判断
它管哪一种技术形态	内容标识。约束的是生成内容的标注与可追溯，不是模型训练，也不是服务准入。
义务主要配置给谁	平台。标识的技术实现与全流程覆盖依赖服务侧，个体没有履行条件。
对教师的影响	转发学生作品时留意标识；备课使用不受影响，因为备课不涉及对外发布。

三个判断合起来，回答了日常最关心的那个问题：这份文件改变了什么、没有改变什么。**知道哪一部分与自己无关，与知道哪一部分与自己有关同样重要。**

意 义　定位能力使规范变化的处理成本，从“等待解读”降到“自行判断”。

06 —— 底线，不是全部

政策解决底线，不解决取舍

政策回答的问题

哪些事不能做；哪些事必须做到什么程度。答案确定，可检查，可追责。

政策不回答的问题

两份都合规的方案之间怎么选。规范不作回答，因为答案取决于具体情境。

取舍依赖的专业判断

教学目标、学生认知阶段、数据最小必要。这三项都不是合规问题，而是判断问题，属于后续各讲的内容。

把政策放在最前面讲，不是因为它是全部，而是因为它是共同的前提。底线不清楚，后面的讨论缺少约束条件；底线清楚之后，伦理判断才有实际对象，安全措施才有明确指向。

分工　合规是必要条件，不是充分条件。

小结 —— 五条理由

为什么先看政策法规

	理由	要点
一	**边界图，不是禁令清单**	边界清楚，可用空间才清楚
二	**了解限制是为了获得自由**	规则越明确，可动作的范围越确定
三	**伦理原则需要制度语言作落点**	义务配置逻辑决定责任归属
四	**政策义务对应技术机制**	备案、标识、内容审核各指向具体技术环节，是理解技术风险的入口
五	**政策体系提供坐标**	新文件可以被自主定位与预判

合起来 了解限制的目的，是获得自由。

合规不是给使用设上限，
而是给使用划出确定的范围。

范围确定之后，动作才可以放开。政策法规提供的是这个范围；在范围之内怎么选，是伦理判断与专业判断要回答的问题，也是后续各讲的起点。