课程名称 · 人工智能伦理与安全

为什么学人工智能伦理与安全要先看政策法规

了解限制，是为了获得自由。

第一讲 · 导论　　面向教学的伦理与安全课程

伦理讲判断，安全讲风险，为什么先看一堆文件

讲人工智能伦理与安全，通常从政策法规开始。这一安排常被质疑：

质疑一 · 三者不在一个层面

伦理讲的是判断，安全讲的是技术风险，政策讲的是文件条款，三者不属于同一类工作。

质疑二 · 文件与日常隔着距离

政策文件冗长、更新频繁、条款细碎，与教师的日常备课上课相距甚远。

先讲政策，是否只是遵循惯例，或者为了给后续内容找一个权威依据。这个问题需要正面回答。

回答不成立，后面的内容就只是知识罗列；回答成立，整门课的讲授顺序才有依据。

政策回答的是三个问题

哪里不能去

禁止进入的区域，对应明确的禁区。

→

哪里可以去

允许使用的空间，对应日常工作的主要部分。

→

可以走多远

允许使用的限度，对应边界模糊的情形。

多数人以为政策就是一张禁令清单，记住的是**不许做什么**。实际不是。两种理解，行为差别很大。

- **只记住禁令的人**，遇到边界模糊的情形只有两个选择：不做，或者做了心里没底。
- **看懂边界的人**，知道可用的空间在哪里、限度在哪里，可以据此安排自己的动作。

边界图回答的是空间问题：限制的位置确定了，可用的空间随之确定。

一个例子：学生作文用 AI 辅助修改，可不可以

只看禁令

想不出答案，索性不用。同一件事，从可做变成不可知，最终以放弃收场。

看了边界

可以用，但**修改痕迹要保留**，**最终评价不能直接采用工具结果**。同一件事，从不敢做变成知道怎么做。

对老师来说，这一差别直接体现为可用空间。不清楚边界，会出现两种方向相反的损失：

- **少用或不用**——在工具已经进入日常工作的环境里，等于让渡效率。
- **不知道边界而越界**——把整张成绩表上传，把生成内容原样提交，事后才知道问题在哪。

两种损失方向相反，来源相同：都不清楚限制的位置。

政策文本自己写明：发展与安全并重

限制与自由不是此消彼长的关系。规则越清楚，可动作的范围越确定，人越敢放开手脚；规则模糊，人只能按最保守的方式行事，实际可用的余地反而更小。

> 《生成式人工智能服务管理暂行办法》 第一条 · 立法目的
>
> **促进健康发展和规范应用**

> 《生成式人工智能服务管理暂行办法》 第三条 · 监管取向
>
> **发展和安全并重 · 实行包容审慎和分类分级监管**

发展与安全并重写在总则里，说明规范的目的不是禁止。

教师规范把大量篇幅花在说明怎么用上

《教师生成式人工智能应用指引（第一版）》，2025 年 11 月发布，是国家层面首份专门面向教师的生成式人工智能规范。核心取向不是禁止，而是引导教师**愿用、会用、善用**。

说明可以怎么用

用六个维度、大量场景示例，逐条给出教师可以使用生成式人工智能的具体做法。

划定不能做的边界

另以行为示例标出不可为之事，为使用划出确定的范围。

一份教师规范把大量篇幅花在说明怎么用上，这本身就是证明。

把原则转成可执行的语言

公平、透明、可问责这些伦理原则，单独说时人人都同意，落到具体情形却难以判断。政策的作用，是把原则转成可执行的语言：

谁承担义务
义务配置给有履行能力的主体。

→

承担到什么程度
义务的强度与范围由条款明确规定。

→

在哪个环节履行
履行环节对应业务流程中的具体位置。

原则一旦落到这三个问句上，判断就不再悬空：面对一个具体情形，可以对照条款确认谁有义务、义务多重、在哪个环节履行，责任归属随之确定。

伦理原则需要制度语言作为落点，义务配置逻辑决定责任归属。

义务主要落在平台，使用者承担剩余义务

服务提供者 · 主要义务

备案、标识、内容审核等义务，主要配置给服务提供者：平台有技术能力履行，个体没有；把义务配置给平台，**监管链条最短**。

使用者 · 剩余义务

使用者承担的义务数量少，但性质是**法定的**，不因不知情而免除。

这一点对老师很实用：

- 知道义务主要落在平台，就不会把工具出错的责任全揽在自己身上。
- 知道剩余义务不可免除，就不会把生成内容原样转发。

责任边界清楚了，才敢用。

两个维度构成一个坐标

人工智能的技术形态还在分化，规范文件持续出台。逐份跟踪不现实，读完的很快过期。真正需要的能力不是记住现有条款，而是一份没见过的文件出现时，能判断它**管的是什么、管到多硬**。

维度一 · 按效力层级分五类

法律、行政法规、部门规章、规范性文件、技术标准，效力与强制程度依次不同。

维度二 · 按规制对象分形态

算法推荐、深度合成、生成式服务、内容标识等，各对应一类技术形态。

任何一份新文件都能在坐标中定位。定位之后，只需两个问句：

它管哪一种技术形态？　义务主要配置给谁？

举个例子：AI 生成内容标识新规出台

一份关于 AI 生成内容标识的新规出台，不必等培训解读，用坐标自己就能判断：

定形态
它管的是内容标识这一技术形态。

→

定义务人
标识义务主要落在平台一侧。

→

看影响
教师转发学生作品时要留意标识，不影响自己备课使用。

- 判断的依据是结构认知：文件在效力层级与规制对象两个维度上的位置。
- 判断的结果是行动边界：哪一步要做什么，哪一步与己无关。

两分钟就能定位。

政策解决底线问题，不解决取舍问题

五

底线问题 · 政策回答

哪些事不能做，哪些事必须做到什么程度。

取舍问题 · 政策不作回答

两份都合规的方案之间怎么选，规范不给出答案。

取舍依赖教学目标、学生认知阶段、数据最小必要这些专业判断，是后面几讲的内容，属于伦理与实践判断的范畴。

把政策放在最前面讲，不是因为它是全部，而是因为它是**共同的前提**。

底线不清楚，后面的讨论缺少约束条件；底线清楚之后，伦理判断才有实际对象，安全措施才有明确指向。

小结

为什么先看政策法规：四条理由

一 **政策给的是边界图，不是禁令清单。**边界清楚，可用空间才清楚。

二 **了解限制才能放开手脚。**规则越明确，可动作的范围越确定。

三 **伦理原则要靠政策落到具体责任。**义务主要落在平台，使用者承担剩余义务。

四 **政策体系提供坐标。**新文件能自己定位、自己判断。

需要说明边界：政策法规解决的是底线问题——哪些事不能做、哪些事必须做到什么程度。它不解决取舍问题，取舍依赖教学目标、学生认知阶段、数据最小必要等专业判断，属于后续各讲的内容。

四条合起来是一句话：**了解限制的目的，是获得自由。**合规不是给使用设上限，而是给使用划出确定的范围；范围确定之后，动作才可以放开。