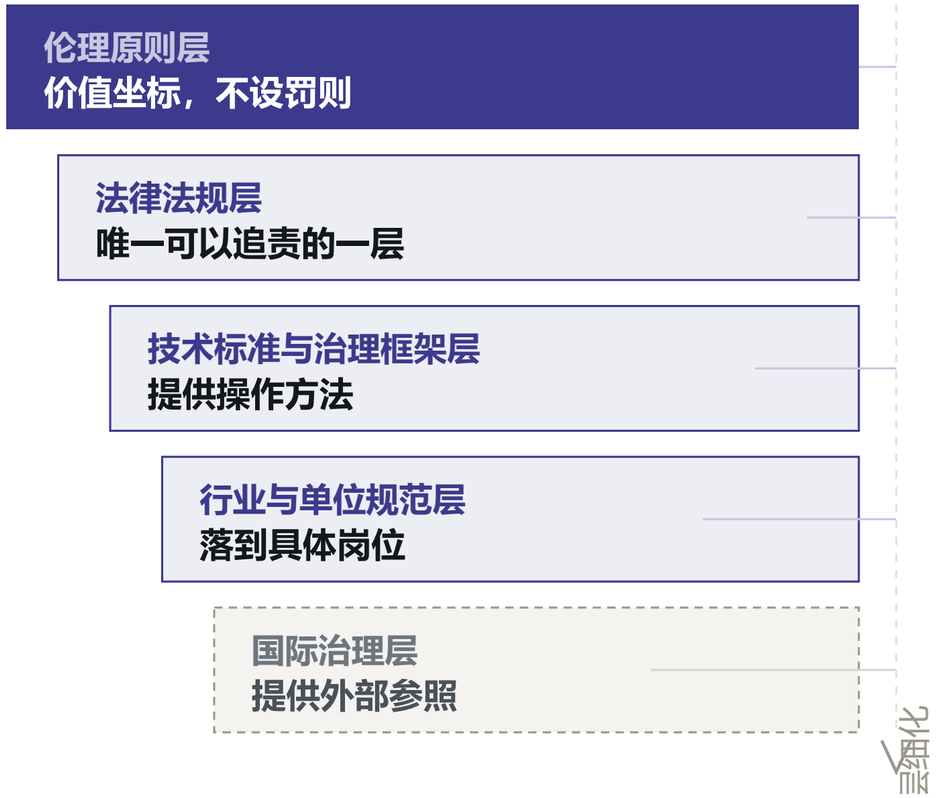
教师人工智能伦理与安全课程　第一部分

人工智能伦理与政策的层次体系



人工智能的要求不是一份文件，而是五个层次构成的一个体系

规范体系的五个层次　　自上而下逐层细化　自下而上逐层回溯

伦理原则层
倡导性文件
规划纲要　治理原则　伦理规范
三份文件依次发布，构成价值坐标
提供价值坐标与解释依据

法律法规层
四法两规章一办法
网络安全法　数据安全法　个人信息保护法　科学技术进步法
生成式人工智能服务管理暂行办法　科技伦理审查办法
唯一可以追责的一层

技术标准与治理框架层
技术指导性文件
安全治理框架一至三版　智能体风险管理专章
标准体系提供控制措施的参照
提供操作方法与控制措施参照

行业与单位规范层
业务规范
教师应用指引　教育强国纲要　人工智能加教育行动计划
地方与学校据此制定实施细则
落到具体岗位，进入师德考核

国际治理层
共识性规范
教科文组织建议书　教师人工智能能力框架
为各国制定政策提供共同语言
提供外部参照，无直接约束力

判断一项要求是否必须执行　先看清它出自哪一层

伦理原则层不是一份文件，而是三份文件四年多层层细化的结果

2017 年 7 月　国务院印发
《新一代人工智能发展规划》

确立三步走目标

2020	总体技术与应用 与世界先进水平同步
2025	基础理论实现重大突破 部分技术与应用达到世界领先
2030	理论、技术与应用 总体达到世界领先水平

治理构想
伦理研究为先导，制度建设为重点

2019 年 6 月　治理专业委员会发布
《新一代人工智能治理原则》

提出八条原则

和谐友好	公平公正
包容共享	尊重隐私
安全可控	共担责任
开放协作	敏捷治理

共担责任的三方
研发者　使用者　受用者

2021 年 9 月　同一委员会发布
《新一代人工智能伦理规范》

细化为六项基本伦理要求

增进人类福祉	促进公平公正
保护隐私安全	确保可控可信
强化责任担当	提升伦理素养

四类活动　十八项具体要求
管理　研发　供应　使用
原则被拆到具体环节，

这一层不设罚则　它确立价值坐标，为下位的法律、标准与行业规范提供解释依据

学校那条禁止上传的通知，不是学校自行加码

学校下发通知

禁止将学生成绩、评语上传至公共人工智能工具

教师看到的全部

↓ 往上追两层，链条才完整

法律法规层

《个人信息保护法》　最小必要原则

收集学生成绩与评语，只为教学评价这一目的，超出该目的的工具即不属必要范围

法律强制力

↓ 再往上，指向价值依据

伦理原则层

《新一代人工智能伦理规范》　保护隐私安全

当具体条文存在空白或出现争议，回到这一层寻找判断依据

倡导性

理解学校要求的分量

不再误认为换个工具就可以绕开

链条看得清　教师既知道要求从哪来，也知道边界在哪里

人工智能专门立法尚未出台，硬性依据由四法两规章一办法撑起

四部法律　两部规章　一部办法

这是五个层次中唯一可以追责的一层

法律　全国人民代表大会常务委员会通过

《网络安全法》
网络运行安全与信息安全的基本法

《数据安全法》
数据处理活动的安全义务

《个人信息保护法》
最小必要原则直接约束教学数据使用

《科学技术进步法》
2021 年修订，从法律层面确立科技伦理治理框架
明确国家建立科技伦理委员会、完善科技伦理制度规范

规章与办法　部门联合印发

《生成式人工智能服务管理暂行办法》
2023 年 7 月 10 日公布　2023 年 8 月 15 日施行

七部门联合公布，其中含教育部
适用于向境内公众提供生成式内容的服务
校内自建、未向公众提供服务的不适用

《科技伦理审查办法（试行）》
2023 年 9 月 7 日印发　2023 年 12 月 1 日施行

单位是本校科技伦理审查管理的责任主体
涉及以人为研究参与者、利用个人信息数据的科技活动
须经伦理审查

讲伦理要落到这一层　只停在倡导层面，教师的重视程度必然打折扣

暂行办法里有三处，讲错就讲成一律不得使用

第一处
适用范围的边界

适用
向境内公众提供生成文本、
图片、音频、视频等内容的服务
面向社会公众的商业产品

不适用
行业组织、企业、教育和科研机构
研发、应用但未向境内公众提供服务
校内自建系统，数据不出校门

校内自建模型用于答疑与材料起草，
适用规则与公共工具并不相同

第二处
治理取向

发展和安全并重
不是先安全后发展，也不是只谈发展

促进创新和依法治理相结合
鼓励应用，同时要求在应用中合规

包容审慎
先允许尝试，边用边完善规则

分类分级监管
按风险高低区别对待，风险高的管得严

监管态度是鼓励应用，不是限制应用

第三处
制定主体

七部门联合公布

国家互联网信息办公室	国家发展改革委
教育部	科学技术部
工业和信息化部	公安部
国家广播电视总局	

教育领域在这部规章的制定中
具有明确的话语位置

教育系统的落实要求不是外部附加的条件 它是规章制定时就在场的考虑

教师用学生课堂数据做研究写论文，同样需要伦理审查

为什么常被漏掉

常见误解
只有医学实验才需要伦理审查
把伦理审查窄化为生物医学领域的事

真实范围
涉及以人为研究参与者、
利用个人信息数据的科技活动

门槛不在于学科
而在于是否涉及人与个人信息

最危险的一句话
「我只是用自己班的数据」

什么算需要报审

触发条件一
以人为研究参与者

触发条件二
利用个人信息数据

↓ 两项中任一成立即进入

科技伦理审查委员会
高等学校、科研机构、医疗卫生机构、企业

↓

须经伦理审查
单位是本校科技伦理审查管理的责任主体

教师场景

以本班学生的
课堂行为数据、作业数据
开展教学研究
用途：论文发表或者项目申报

↓

涉及个人信息数据的
采集与分析
属于审查范围

教师在此之前并不知道
这类研究需要报审

报审不是走形式 它把教学数据的采集与分析放进了制度化的程序里

技术治理框架三年三版，第三版新增智能体风险管理专章

1.0 版　2024 年 9 月 9 日

内生风险

模型算法安全　数据安全　系统安全

应用风险

网络域　现实域　认知域　伦理域

2.0 版　2025 年

延续核心逻辑

风险分类　技术应对　综合治理

提出技术应对与综合防治措施

3.0 版　2026 年 9 月 14 日

显著变化

增设《智能体风险管理框架》专章

成体系梳理智能体安全风险与防范

这一层是什么性质

技术指导性文件

不创设行政许可

不创设备案义务

不创设民事赔偿义务

价值：为组织识别风险、配置控制措施提供参照

学校制定本校管理办法时，最直接的技术依据

标准体系支撑

涵盖基础共性、关键技术、产品应用等层面

伦理标准是其中的重要组成部分

全国网络安全标准化技术委员会下设

人工智能安全标准工作组，持续产出实践指南

标准不追责　但学校写细则时，抄的就是这一层

助手一旦能调用工具，风险就从「说错话」变成「做错事」

一个常见场景

某教师为节省时间，授权助手代为处理邮件

整理邮箱
批量读取与归类

自动逐封回复家长来信
自动生成并发送

助手具备的权限
调用工具　访问数据　执行操作

无人复核的操作
完成之后不可撤回

风险
升级

以前的形态

说错话

风险只在生成的内容里
教师看到回复，删掉重写即可
后果停留在纸面，可逆

发出去的内容

写错了，可以重写
发错了，可以追回

现在的形态

做错事

越权读取其他邮件

把内部信息带入回复

在无人复核的情况下完成
不可撤回的操作

这正是治理框架增设智能体专章的原因
风险不再只靠内容审核能兜住

授权即扩大风险面　给助手多大权限，决定了风险有多大

教育领域首份面向教师的生成式人工智能指引，用两张清单说话

2025 年 11 月　教育部教师队伍建设专家指导委员会发布
《教师生成式人工智能应用指引（第一版）》

教育领域首份专门规范文件

场景指引　正面清单　可以怎么用　三十个场景示例

- **助力学习变革**：支持学生自主学习
- **教学提质**：备课与资源建设
- **育人进阶**：个性化指导与陪伴
- **评价增效**：作业与反馈设计
- **管理升级**：日常事务与协同
- **研究创新**：教学研究与探索

规范指引　约束清单　什么不能做　十八个行为示例

划定底线红线

正面清单说明可以怎么用
约束清单说明什么不能做
两者同时存在，才是完整的规范

文件同时明确三方职责

教育行政部门　**学校**　**企业**

学校应据此制定细则与操作指南

学校尚未制定细则，不等于没有规范要求　上位规范已经生效

同一时期的文件既要求规范，也在要求教师把人工智能用起来

教育系统的上位部署与规范文件在同一时期并行

规范的一侧 教师行为边界

《教师生成式人工智能应用指引（第一版）》

《教育强国建设规划纲要（2024—2035 年）》

鼓励的一侧 教师数字素养

「人工智能+教育」行动计划　2026 年 4 月　五部门联合印发

全面提升教师的数字素养和技能

政策取向：鼓励使用，规范使用

误读一　把规范理解为限制

有教师看到规范文件后，判断此后不得再用人工智能备课

事实：同一时期的国家文件正在要求提升教师数字素养

误读二　把鼓励理解为放任

文件在鼓励应用的同时，明确列出不能做的十八个行为示例

事实：同一时期的国家文件正在划定行为边界

两面必须同时讲到位　既不会因鼓励而放任，也不会因规范而止步

教师感受最直接、差异最大的一层，是地方与学校的具体细则

地方层面
北京、上海、广东等十一个地方
已出台人工智能赋能教育的文件
以省级文件为主

省级层面
山东、云南、黑龙江等地
已就教师使用人工智能工具
提出细化要求

学校层面
制定落地的实施细则与操作指南
尚未制定细则不等于没有规范要求
上位规范已经生效，
细则滞后于规范，而不是规范不存在

逐级
细化

《北京市教育领域人工智能应用指南（2026 年）》 针对高等教育建立三类清单

禁止准入
明确不得进入教学环节

触碰即违规
不存在裁量空间
直接进入追责范围

有限使用
在明确条件下可以使用

条件写在前置
不满足条件即不适用
看条件再看工具

鼓励使用
政策积极鼓励的方向

教师主动应用
进入考核加分项
不是可有可无

引用注意
该表述依据公开报道，引用时宜以原文为准

这一层违反通常不直接产生法律责任 但会进入师德考核、教学管理与职业行为评价

国际治理层不约束教师，它的意义是让本国规范有坐标可依

两份代表性文件

2021 年　联合国教科文组织成员国通过
《人工智能伦理问题建议书》
全球首份人工智能伦理领域综合性国际标准文件
涉及人权、透明度、责任、数据治理、环境影响与算法歧视
不具直接处罚效力，提供共同语言与参照框架

2024 年 8 月　教师人工智能能力框架

五个维度　十五项能力　三个进阶水平

思维方式	**伦理**	基础与应用	教学法	专业学习

习得　深化　创造
伦理被单列为五大维度之一，是核心能力而非附属内容

主要经济体的治理路径存在差异

欧盟　**统一立法路径**
2018 年起陆续发布
《人工智能助力欧洲》
《关于人工智能——卓越与信任的欧洲路径白皮书》

英国　**原则驱动　行业主导**
以原则为出发点
行业主导的分散治理模式
不追求统一立法，
由行业自行制定规则

中国　**发展安全并重**
发展与安全并重
分类分级监管的路径
把发展放在与安全并列的位置，
强调在应用中完善规范

差异的实质是价值排序与制度传统不同　对教师而言，实际意义在于拓展视野，理解本国规范在国际坐标中的位置

这一层不追责，但有用　它提供共同语言，让国内实践知道自己站在哪里

五层不是并列关系，而是一条上细下溯的链

自上而下　逐层细化

- **伦理原则层**
  提供价值依据
- **法律法规层**
  确立强制约束
- **技术标准层**
  提供操作方法
- **行业规范层**
  落到具体岗位
- **国际治理层**

自下而上　逐层回溯

- **伦理原则层**
  法律未规定时，回到这里找解释依据
- **法律法规层**
  判断有没有触及可以追责的底线
- **技术标准层**
  判断本校细则的边界在哪里
- **行业规范层**
  遇到未覆盖情形，往上找上位依据
- 国际治理层　外部参照

教师每天真正走的那条线

起点　学校规定、单位制度
这是日常接触最多的一层，也是唯一能直接约束你的层

↓

往上找　这份规定的依据是什么
不要求每条都查到，但知道该往哪一层找

↓

再往上　它有没有低于上位法的底线
下位规定不得与上位法冲突，这是效力顺序

链条看得懂，遇到新情况才不慌

自上而下细化，自下而上回溯　这两条方向缺一条，链条就断了

不同层级的要求出现张力时，只有一条裁决规则可用

三条效力规则　按顺序适用

一　法律层优先

法律已有明确规定时，一切以法律为准
下位规范与之冲突的，冲突部分无效

例
行业规范要求可以上传，
若与最小必要原则冲突，以法律为准

二　法律没有明确规定时，以伦理原则层作为解释依据

条文存在空白或出现争议，回到价值坐标去找答案
这是治理实践中的通行做法

例
校内自建模型是否可用，法律未直接规定，
回到伦理规范中保护隐私安全的要求

三　行业规范与单位制度不得低于上位法设定的底线

地方文件可以更严，不能更松
本校细则收紧属于允许，放宽则属于越权

例
某地禁止使用某工具，比上位法更严，
这是允许的收紧，不是违规

国际治理层不参与国内效力排序　它提供参照，不设定约束

效力顺序不是抽象理论　它决定了一条学校通知到底能不能执行

记住这一讲只需要三句话，而这三句都要落到行动上

第一点

日常接触最多的是行业与单位规范层，只有理解前三层才知道本校条文的依据与边界

遇到学校规定未覆盖的情形
知道往哪里找依据

行动
先判断它出自哪一层，再决定怎么执行

第二点

五个层次中只有法律法规层可以追责，讲授伦理若不落到这一层，容易停留在道德劝诫

停留在倡导层面
教师的重视程度必然打折扣

行动
把伦理要求往法律依据上落一步

第三点

政策总取向是鼓励应用、规范使用，两种误读都会让教师走错方向

把规范理解为限制
因规范而止步

把鼓励理解为放任
因鼓励而放任

三句话的落点 知道去哪找依据、知道哪一层能追责、知道总取向不是限制

讲授时把文件语言换成日常语言，遇到追问再展开

文件里的说法		课堂上换成的说法
部门规章	→	几个部委联合发布、具有处罚权的规定
上位法	→	层级更高的法律，下位规定不得与其冲突
备案与许可	→	事前向主管部门报备、事前经主管部门批准
伦理审查	→	由专门机构对研究方案是否合规作出的事前审核
分类分级监管	→	按风险高低区别对待，风险高的管得严
包容审慎	→	先允许尝试，边用边完善规则
内生风险与应用风险	→	工具自身可能出的问题，以及用到具体场景后才出现的问题
智能体	→	**能够自行操作工具、执行任务的人工智能**

先说人话，再讲依据　把名词换掉不等于降低标准，只是让标准被听懂

这一讲讲的不是文件清单，是教师判断要求出处的坐标系

五个层次，一条链条

伦理原则层
价值坐标

法律法规层
强制约束

技术标准层
操作方法

行业规范层
具体岗位

国际治理层
外部参照

这一讲留下的三句话

一　要求不是一份文件，而是五个层次构成的一个体系

五层各有各的性质：倡导、法律强制、技术指导、业务规范、外部参照。
判断一项要求是否必须执行，先看清它出自哪一层。

二　只有法律法规层可以追责，讲伦理必须落到这一层

伦理原则层不设罚则，技术标准层不创设义务，行业规范层的约束来自管理关系。
要求立得住，教师才会当真。

三　总取向是鼓励应用、规范使用，两种误读都要避开

鼓励不等于放任，规范不等于限制。把两面同时讲到位。
既不会因鼓励而放任，也不会因规范而止步。

这一讲是坐标，不是终点。后面几讲的风险划分，源头都在这五层里。

先看层，再看文　这是这一讲唯一要带走的东西