人工智能伦理与安全系列课程

人工智能伦理与安全的政策与法律

从文件清单到体系结构

—— 不逐条读文件，讲清楚这些文件构成什么结构

目录

一 讲授起点与体系规模 文件为什么读不完 · 五类效力层级 · 两种排法的局限

二 体系的两个独立维度 技术形态与效力层级 · 独立方向的数量为二

三 文件的坐标定位 效力层级 × 技术形态 · 逐份文件在平面上的位置

四 维度成因与三条主线 形态为何可切分 · 使用者承担剩余义务 · 三条取向

五 判断新文件与教师含义 两个问句 · 一件日常操作横跨三个形态 · 三点含义

本讲的目标不是让你记住更多文件名，而是给你一套**判断新文件位置的结构**。

本讲不逐条讲文件

各位老师面对的处境

一 需要遵守的规范文件很多，**逐份读完不现实**

二 新文件仍在持续出台，**读完的很快过期**

三 真正遇到问题时，**不知道该援引哪一份**

本讲不做的事

不逐条讲文件

本讲要做的事

讲这些文件构成什么结构

> 结构清楚了，任何一份新文件出台，都能在**两分钟内**判断它属于体系内的**常规增补**，还是**体系本身发生了变化**。

本讲路线 体系规模 → 两个维度 → 坐标定位 → **判断新文件**

五类效力层级与代表文件

法律 四部 · 授权基础	尚无人工智能专门立法。《**网络安全法**》《**数据安全法**》《**个人信息保护法**》《**科学技术进步法**》构成下位规范的主要授权基础。
行政法规 基础性规定	主要是《**互联网信息服务管理办法**》。该办法在多份部门规章的第一条中被直接援引，是体系中真实存在的**连接点**，承担承上启下的作用。
部门规章 数量最多	《算法推荐管理规定》《深度合成管理规定》《生成式人工智能服务管理暂行办法》《人工智能生成合成内容标识办法》 多数部门规章的第一条，援引的是上列四部法律。
规范性文件 伦理与框架	《新一代人工智能伦理规范》《人工智能安全治理框架》系列
技术标准 配套落地	《人工智能科技伦理审查与服务办法（试行）》《人工智能应用伦理安全指引1.0》以及配套**强制性国家标准**

截至当前，直接涉及人工智能伦理与安全的规范性文件，按效力层级可分为**五类**。

规章最多，标准配套落地

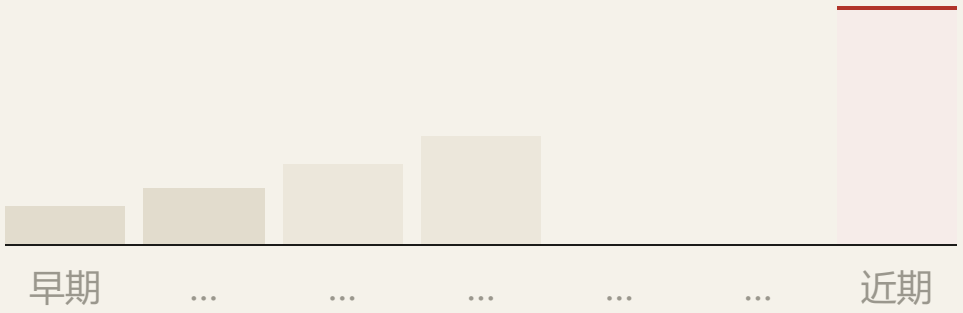
效力层级	代表文件	在体系中的位置
法律	《网络安全法》《数据安全法》《个人信息保护法》《科学技术进步法》	下位规范的主要授权基础
行政法规	《互联网信息服务管理办法》	被多份规章第一条直接援引
部门规章	《算法推荐管理规定》《深度合成管理规定》《生成式人工智能服务管理暂行办法》《人工智能生成合成内容标识办法》	**数量最多·义务最具体**
规范性文件	《新一代人工智能伦理规范》《人工智能安全治理框架》系列	价值取向与风险分类
技术标准	《人工智能科技伦理审查与服务办法（试行）》《人工智能应用伦理安全指引1.0》及配套强制性国家标准	伦理要求落到审查与执行

五类层级及其代表文件可归为下表，**讲授时可直接指表展开**。

时间与主题两种排法的局限

按时间排列

得到一条**逐年加密的曲线**。文件持续出台，早期规范长期有效，后期规范密集跟进。



或

按主题排列

得到**数据、算法、内容、安全**四组，但四组之间**大量交叠**。

数据
个人信息保护、数据安全

算法
算法推荐、备案

内容
深度合成、生成式、标识

安全
安全治理框架、伦理审查

算法类文件必然涉及数据，内容类文件必然涉及安全。

两种排法都能列出文件，都无法回答一个问题：**为什么是这些文件，而不是另外一些**。

二 —— 体系的两个独立维度

独立方向只有两个

把上述文件的属性逐项编码，会发现**表象虽多，独立方向只有两个。**

维度一

规制对象的技术形态

算法推荐、深度合成、生成式服务、生成合成内容标识、科技伦理审查——**每一种形态成熟到一定程度，便出现一份与之对应的规范。**

回答的是：管什么

维度二

效力来源的层级

从法律到技术标准，**同一技术形态可以在不同层级反复出现。**形态固定而硬度可变。

回答的是：由谁管、管到多硬

秩 = 二

两个维度构成一个**坐标平面**，独立方向的数量为二。此处借「秩」表示独立方向的数量，非矩阵秩的严格意义。

义务差别无需第三个维度

其余差异均为**派生**。以两份文件为例——

《算法推荐管理规定》

重在

- 用户**选择权**
- **算法备案**

针对**推荐算法**这一形态

≠

《生成式人工智能服务管理暂行办法》

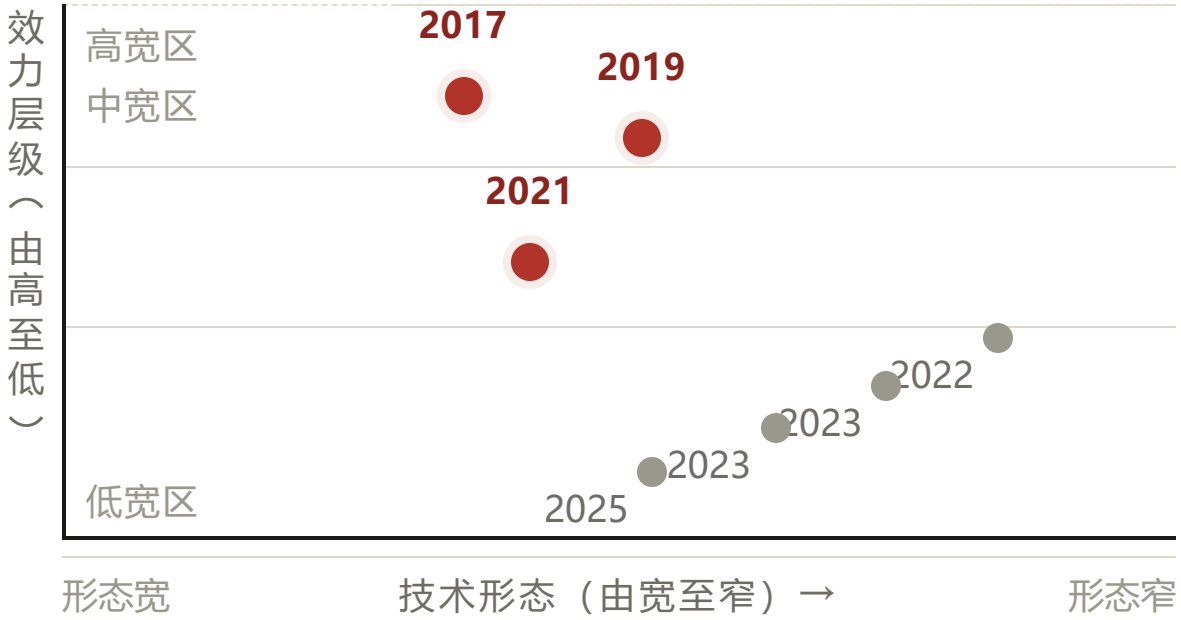
重在

- **训练数据合法性**
- **内容标识**

针对**生成式服务**这一形态

形态不同，义务自然不同。这一差别**不需要第三个维度**来解释。

坐标轴与点的读法



读法　纵轴为**效力层级**，由法律到技术标准自上而下排列；横轴为**技术形态**，覆盖范围由宽到窄。文件以点标注，其**横向跨度**表示所覆盖形态的宽窄。

图例

2017 发展规划　2019 治理原则　2021 伦理规范
2022 算法推荐　2023 深度合成　2023 生成式　2025 标识办法

高宽区 · 多年稳定

2017《新一代人工智能发展规划》位于层级高、形态宽的位置，因**不针对具体技术形态**，故多年保持稳定。

高宽区 · 价值取向

2019《新一代人工智能治理原则》同属高宽区，承担价值取向功能，提出**八条原则**：

和谐友好	公平公正	包容共享	尊重隐私
安全可控	共担责任	开放协作	敏捷治理

中宽区　**2021《伦理规范》**层级中等、形态宽，首次把**使用主体**单列为规范对象。

伦理规范首次单列使用主体

2021 **《新一代人工智能伦理规范》** 层级中等 · 形态宽

其重要作用在于**首次把使用主体单列为规范对象**，提出管理、研发、供应、使用四类活动共**十八项**具体要求，其上是**六项**基本伦理要求。

六	+	十八
基本伦理要求		具体要求

与本课程直接相关

教师属于**使用主体**。这一条是本课程与《伦理规范》之间的直接接口。

伦理规范首次把教师所在的位置——**使用主体**——写进了规范对象。

三份规章的义务各自具体

2022	**《互联网信息服务算法推荐管理规定》** 义务高度具体：**算法备案** · **用户关闭个性化推荐的选项** · **人工干预机制**	2021年12月31日公布 2022年3月1日起施行
2023	**《互联网信息服务深度合成管理规定》** 核心义务：对**人脸生成替换**、**合成内容作显著标识**	2022年11月25日公布 2023年1月10日起施行
2023	**《生成式人工智能服务管理暂行办法》** **训练数据合法性** · **内容标识** · **未成年人保护**；明确对生成式服务实行**包容审慎**和**分类分级**监管	七部门联合公布 2023年8月15日起施行

三份规章同处**层级低、形态窄**的窄低区，义务高度具体。

三 —— 文件的坐标定位

标识义务细化为两类

显式标识

在生成合成内容及其交互界面中，以**显著方式**向公众提示内容由人工智能生成。

隐式标识

在生成合成内容的文件元数据中嵌入**隐式信息**，用于溯源与验证。

2025《人工智能生成合成内容标识办法》

把标识义务**细化为显式与隐式两类**。

2023年7月13日由七部门联合公布，2023年8月15日起施行。

GB 45438-2025

《网络安全技术 人工智能生成合成内容标识方法》配套**强制性国家标准**，对标识的**时长、面积**作出量化规定。

与《标识办法》同日于2025年9月1日施行。

同日施行：一部办法与一部强制性国标，构成**义务 + 量化标准**的配套结构。

三 —— 文件的坐标定位

治理框架按年度迭代

《人工智能安全治理框架》系列

2024年首发 · 层级低、形态宽

1.0	2.0	3.0
2024年9月发布	2025年9月发布	2026年9月发布

从风险分类切入

为各类形态共用，核心逻辑为**风险分类 → 技术应对 → 综合治理**。位于低宽区，管框架不管具体操作。

3.0版最实质的变化

增设**智能体风险管理专章**，按全生命周期梳理智能体各环节风险及对应防范措施。

反映治理对象已从「**回答问题**」扩展到「**执行任务**」。

三 —— 文件的坐标定位

伦理审查与指引同属低层宽面

2026《人工智能科技伦理审查与服务办法（试行）》

由工业和信息化部等**十部门**联合印发，文号**工信部联科〔2026〕75号**。把伦理要求从**原则倡导**推进到**审查与落实**环节。

《人工智能应用伦理安全指引 1.0》

由全国网络安全标准化技术委员会于2026年5月发布，编号**TC260-005**。属技术文件，给出**应用开发、服务提供、应用使用**三类主体的伦理安全指引。

坐标定位 —— **层级低 · 形态宽**

定位完成后，一条规律浮现：**形态宽而层级高**的文件更新频率低，**形态窄而层级低**的文件更新频率高。
前者管方向，后者管操作。

形态可切分而风险难切分

维度一之所以是技术形态

技术迭代周期短于立法周期，而技术形态可以清晰切分，风险却难以清晰切分。

按形态立法，每出现一种新形态，**增补一份文件即可**，不必等统一法典。

代价是规范分散。

维度二之所以是层级

原因在于**义务的可执行性**。

备案、标识、内容审核，**平台具备履行的技术能力，个体不具备。**

把主要义务配置给服务提供者，监管链条最短、执行成本最低。

形态是立法成本的解，层级是执行成本的解。**两个维度各有其成因，不是一般性的分类偏好。**

使用者承担剩余义务

由此产生一个必须讲清的事实：**义务主要配置给服务提供者，使用者承担的是剩余义务。**

配置依据

各规章的**责任条款多以服务提供者为主体**；使用者义务则散见于个人信息保护的一般法律，以及各规章中关于使用行为的具体条款。

剩余义务的性质

数量少，但**不可免除**。教师的合规责任，正落在这个位置。

它不来自某一份人工智能规章，而来自**个人信息保护的一般法律**，以及**各规章中关于使用行为的具体条款**。

教师的合规责任来源分散、条款隐蔽——这正是需要先讲清体系结构的原因。

一件日常操作横跨三个形态

这一结构在具体场景中并不抽象。一位教师用某款 AI 工具**生成课件插图**——

生成式服务

该工具提供生成能力，落入《生成式人工智能服务管理暂行办法》

→

内容标识

生成内容带标识义务，落入《人工智能生成合成内容标识办法》

→

算法推荐

若该工具还向学生推荐学习资源，则又涉及算法推荐规范

同一件操作，三条并行的义务链

① 服务提供者

训练数据合法 · 内容显著标识

② 内容标识

显式标识 · 隐式标识 · 元数据

③ 使用者（教师）

传播时不得删除标识

常见误判

先找文件、再套用条款

正确顺序

先判断形态，再找文件

同一件日常操作，横跨三个形态。教师首先要做的不是找文件，而是**判断形态**。

四 —— 维度成因与三条主线

三条不写在文件里的取向

两个维度之外，还有三条贯穿全部文件的取向。它们**不写在任何一份文件里**，却是所有文件共同的出发点。

一 发展与安全并重

规范的目的在于让应用可持续，**不以禁止替代治理**。《生成式人工智能服务管理暂行办法》第一条即同时列出**促进发展**与**防范风险**两项立法目的。

二 分类分级

不设统一门槛，按技术形态与风险程度分别设定要求。这一取向在安全治理框架的版本迭代中体现得最为清楚。

三 伦理先行于法律

伦理规范、伦理审查办法**先于专门立法出台**，伦理要求承担了在法律缺位时提供判断依据的功能。

三条取向的共同落点	不禁止 而设条件	不设统一门槛 而分级	法未定时 伦理先判

伦理先行是治理取向

「伦理先行」是什么

是**治理取向**的表述，**非法律原则**。它描述的是文件出台的先后与功能分工，不是法律位阶上的概念。

它不是什么

不意味伦理要求可以替代法条，也不意味着伦理规范具有强制约束力。二者功能不同：法律解决**必须做什么**，伦理提供**应当怎么做**的判断依据。

这一顺序决定了什么

一 教师在实践中遇到的**许多问题**，没有可直接援引的法条

二 可依据的是**伦理指引**——《伦理规范》《伦理审查办法》《伦理安全指引》

三 因此，讲清「哪些是法律、哪些是伦理」，本身就是合规能力的一部分

有专门规章 该规章的具体条款 + 上位法依据

仅有伦理文件 伦理规范、伦理审查办法、伦理安全指引

没有法条可援引时，**伦理指引就是判断依据**。

两个问句定文件性质

体系结构稳定之后，判断一份新文件的性质**只需两个问句。**

一问

它管的是哪一种技术形态

- 若指向某一**具体形态** → 属**常规增补**，在坐标上落在形态窄的区域
- 若指向**全部形态** → 可能是**层级提升**或**方向调整**

二问

它的义务主要配置给谁

- 若仍以**服务提供者**为主 → **体系未变**
- 若开始向**使用者、组织者**大量配置义务 → 属**结构变化**，教师的合规负担会随之改变

两个问句的价值在于：把对新规的**被动等待**，转为主动**预判**。

五 —— 判断新文件与教师含义

以深度合成规定走一遍

《互联网信息服务深度合成管理规定》 样例文件

一问形态

指向**深度合成**这一具体形态 → 属**常规增补**。

→

二问义务主体

主要配置给**深度合成服务提供者**，要求其对生成内容作显著标识；使用者仅在传播环节承担不得删除标识的义务。

结论：该文件**未改变体系结构**。教师只需在**传播他人合成内容**时注意标识完整。

两个问句走完，判断结束——不必通读全文，不必等别人解读。

教师的三点含义

一 教师处于使用主体位置

义务数量少，但性质是**法定的**，**不因「我不知道」而免除**。因此需要读懂结构，不必通读全文。

二 具体问题多数落在形态边界上

首要动作是判断所用产品属于哪一类服务：**推荐算法**、**深度合成**、**生成式服务**，还是仅涉及**内容标识**。

形态判断错了，援引的文件就错了。

形态判断清单：产品是什么

推荐内容	合成人脸	生成图文	对外分发
算法推荐	**深度合成**	**生成式服务**	**内容标识**
可关闭个性化	不得删标识	内容标识	显式 + 隐式

合规只解决底线

三　合规只解决底线，不解决取舍

两份都合规的方案之间如何选择，规范不作回答。

取舍的判断顺序

一　先看**教学目标**是否需要该功能

二　再看**学生认知阶段**是否适配

三　最后看所用**数据是否满足最小必要**

三点合起来，回到开篇的承诺：结构清楚之后，一份新文件摆在面前，**两个问句即可定位**，不必等别人解读。