人工智能伦理与安全系列课程

第一讲
人工智能伦理与安全的政策与法律
——从文件清单到体系结构

不逐条读文件，讲清楚这些文件构成什么结构

讲授的起点

各位老师的日常处境

一 需要遵守的规范文件很多，逐份读完不现实

二 新文件仍在持续出台，读完的很快过期

三 真正遇到问题时，不知道该援引哪一份

本讲不做的事

不逐条讲文件

本讲要做的事

讲这些文件构成什么结构

> 结构清楚了，任何一份新文件出台，都能在两分钟内判断：它属于体系内的常规增补，还是体系本身发生了变化。

体系的实际规模：五级效力层级

法律	尚无人工智能专门立法。《网络安全法》《数据安全法》《个人信息保护法》《科学技术进步法》构成全部下位规范的授权基础——任何一份部门规章的第一条，援引的都是这几部法律。
行政法规	《互联网信息服务管理办法》等基础性规定。
部门规章	数量最多的一层：《互联网信息服务算法推荐管理规定》《互联网信息服务深度合成管理规定》《生成式人工智能服务管理暂行办法》《人工智能生成合成内容标识办法》。
规范性文件与技术标准	《新一代人工智能伦理规范》《人工智能安全治理框架》系列、《人工智能科技伦理审查与服务办法（试行）》《人工智能应用伦理安全指引》，以及配套强制性国家标准。

清单的两种排法，与一个共同盲点

按时间排列

得到一条逐年加密的曲线：二〇一七年起，文件出台节奏持续加快。

按主题排列

得到数据、算法、内容、安全四组——但四组之间大量交叠：算法类文件必然涉及数据，内容类文件必然涉及安全。

共同盲点

两种排法都能列出文件，但都无法回答一个问题——

> **为什么是这些文件，而不是另外一些？**

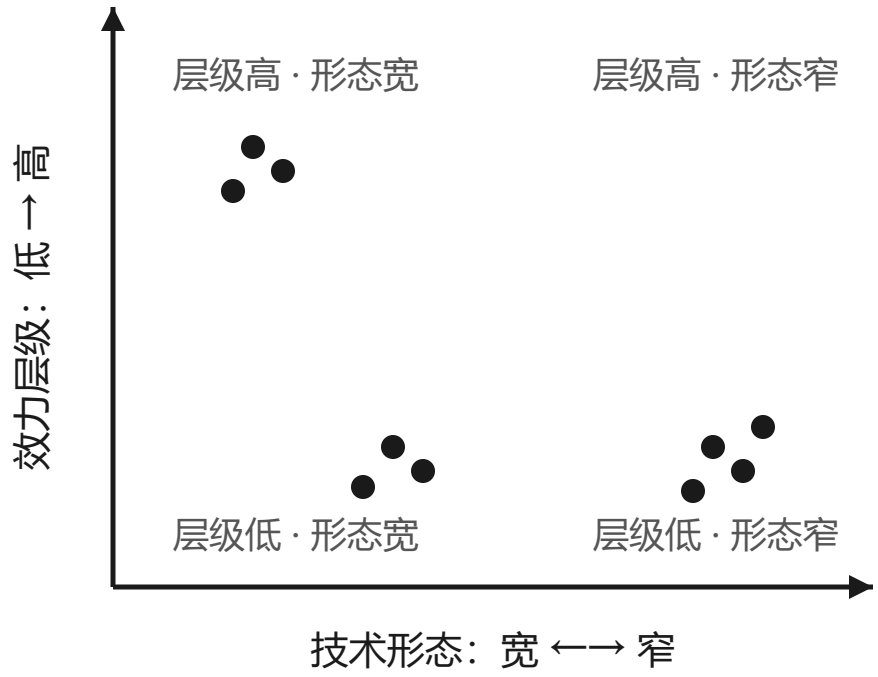
体系的两个独立维度

把文件属性逐项编码，表象虽多，独立方向只有两个。

一 **规制对象的技术形态**——管什么。算法推荐、深度合成、生成式服务、生成合成内容标识、科技伦理审查：每一种形态成熟到一定程度，便出现一份与之对应的规范。

二 **效力来源的层级**——由谁管、管到多硬。从法律到技术标准，同一技术形态可以在不同层级反复出现。

其余差异均为派生，两个维度构成一个坐标平面，秩为二。



义务差别很大，为什么不需要第三个维度

对比项	互联网信息服务算法推荐管理规定	生成式人工智能服务管理暂行办法
对应形态	推荐算法这一形态	生成式服务这一形态
义务重点	用户选择权、算法备案、人工干预机制	训练数据合法性、内容标识、未成年人保护
监管取向	针对既有形态的常规规制	包容审慎、分类分级监管

义务内容的差别不需要第三个维度解释：

前者针对推荐算法这一形态，后者针对生成式服务这一形态——形态不同，义务自然不同。

在坐标上定位：层级高、形态宽的三份文件

年份	文件	定位与功能
二〇一七	**新一代人工智能发展规划**	层级高、形态宽。不针对具体技术形态，故多年保持稳定。
二〇一九	**新一代人工智能治理原则**	同属高宽区，承担价值取向功能。
二〇二一	**新一代人工智能伦理规范**	层级中等、形态宽。首次把**使用主体**单列为规范对象，提出管理、研发、供应、使用四类活动共十八项具体要求。**教师属于使用主体——这一条与本课程直接相关。**

高宽区文件的功能：管方向、立价值，不随单项技术的起伏而修订。

在坐标上定位：层级低、形态窄的四份文件

年份	文件	核心义务
二〇二二	**互联网信息服务算法推荐管理规定**	算法备案、用户关闭个性化推荐的选项、人工干预机制。
二〇二三	**互联网信息服务深度合成管理规定**	对人脸生成替换、合成内容作显著标识。
二〇二三	**生成式人工智能服务管理暂行办法**	训练数据合法性、内容标识、未成年人保护；对生成式服务实行包容审慎和分类分级监管。
二〇二五	**人工智能生成合成内容标识办法**	把标识义务细化为显式标识与隐式标识两类；配套强制性国家标准对标识的时长、面积作出量化规定。

窄低区文件的功能：管操作，义务高度具体，随单项技术成熟而出台。

在坐标上定位：层级低、形态宽的文件，与一条规律

二〇二四 首发安全治理框架系列

从风险分类切入，为各类形态共用，已迭代至**三·〇版**。核心逻辑：风险分类、技术应对、综合治理。

二〇二六 伦理审查与伦理安全指引

《人工智能科技伦理审查与服务办法（试行）》《人工智能应用伦理安全指引》，把伦理要求从原则倡导推进到**审查与落实**环节。

定位完成后，一条规律浮现：

形态宽、层级高的文件，更新频率低

它们管方向。

形态窄、层级低的文件，更新频率高

它们管操作。

两个维度的成因

为什么第一维是技术形态

- 技术迭代周期短于立法周期。
- 技术形态可以清晰切分，风险却难以清晰切分。
- 按形态立法：每出现一种新形态，增补一份文件即可，不必等统一法典。

> 代价是规范分散。

为什么第二维是层级

- 取决于义务的可执行性。
- 备案、标识、内容审核——平台具备履行的技术能力，个体不具备。
- 把主要义务配置给服务提供者，监管链条最短、执行成本最低。

> 层级即执行能力的分布。

一个必须讲清的结构性事实

义务主要配置给服务提供者，使用者承担的是剩余义务。剩余义务数量少，但不可免除。

教师的合规责任落在哪里

- 正落在「使用者剩余义务」这个位置。
- 它不来自某一份人工智能规章。
- 它来自个人信息保护的一般法律，以及各规章中关于使用行为的具体条款。

对本讲的意味

读懂结构，比通读全文更重要——因为教师的义务不在某一份专门文件里，而在体系的结构关系里。

体系的三条主线

两个维度之外，还有三条贯穿全部文件的取向——它们不是文件，而是文件共同的出发点。

一 **发展与安全并重。**规范的目的在于让应用可持续，不以禁止替代治理。《生成式人工智能服务管理暂行办法》第一条即同时列出促进发展与防范风险两项立法目的。

二 **分类分级。**不设统一门槛，按技术形态与风险程度分别设定要求。这一取向在安全治理框架的版本迭代中体现得最为清楚。

三 **伦理先行于法律。**伦理规范、伦理审查办法先于专门立法出台，伦理要求承担了在法律缺位时提供判断依据的功能。

> 这一顺序决定了：教师在实践中遇到的许多问题，没有可直接援引的法条，只有伦理指引。

用两个问句判断新文件

一问：它管的是哪一种技术形态

若指向某一具体形态——属常规增补，在坐标上落在形态窄的区域。

若指向全部形态——则可能是层级提升或方向调整。

二问：它的义务主要配置给谁

若仍以服务提供者为主——体系未变。

若开始向使用者、组织者大量配置义务——属结构变化，教师的合规负担会随之改变。

这两个问句的价值在于：把对新规的被动等待，转为主动预判。

对教师的三点含义

一 **教师处于使用主体位置。**义务数量少，但性质是法定的，不因「我不知道」而免除。因此需要读懂结构，不必通读全文。

二 **具体问题多数落在技术形态的边界上。**首要动作是判断所用产品属于哪一类服务：是推荐算法、是深度合成、是生成式服务，还是仅涉及内容标识。形态判断错了，援引的文件就错了。

三 **合规只解决底线，不解决取舍。**两份都合规的方案之间如何选择，规范不作回答——这属于后续各讲的内容。

需要提醒的一处变化

本讲所依据的文件名称与施行时间，已按现行公开信息核对。其中两点须特别注意：

一　**《人工智能安全治理框架》已迭代至三·〇版**，讲义引用时不可停留在初版。

二　**二〇二六年新出台的伦理审查办法与伦理安全指引两份文件**，尚未被多数既有培训材料收录，属于本讲相对前沿的部分。

> 讲义定稿前建议再核对一次官方原文，尤其是配套强制性国家标准的量化条款。