教师人工智能伦理与安全课程　第二部分之二

## 两类风险的治理指向与结论

# 人工智能的风险从何而来

**内生风险**
规范不能消除

**外生风险**
规则与流程防得住

应对
**核验　审查　留痕**
不改变工具，只改变人的做法

应对
**明确责任　明确边界**
规则清楚，概率显著下降

**规则缺失**
**制度供给滞后于实践，须单独处理**

全篇结论
**风险有来源、可分辨、可控制**
出错先分辨风险属于哪一类
内生完成核验　外生补足流程

# 目录


第一章 **内生风险的三个控制环节**

规范不能消除　核验　审查　留痕

第二章 **外生风险的制度防范**

规则与流程　规则缺失　制度滞后　空白期处理

第三章 **规则缺失与全篇结论**

风险有来源　可分辨　可控制　出错先分辨类型

# 规范不能消除内生风险，区分是为了选对应对方式

**两类风险的区分，不是概念上的分类，而是指向不同的应对方式**

规范尝试一
**要求教师更谨慎** ⊗→ 消除不了
**不能使模型不再编造文献**

规范尝试二
**要求学校加强管理** ⊗→ 消除不了
**不能使输出变得可复现、可解释**

原因在机理：编造、不可复现、不可解释，都来自概率生成机制本身，与使用者的态度和管理者的力度无关

↓

**出路** **不改变工具的行为，只改变人的工作方式**
应对落在三个环节：核验、审查、留痕

**本章落点** 内生风险的出路不在要求更严，而在环节更实

# 应对内生风险，落在核验、审查、留痕三个环节

## 一 核验　使用前

**对事实性内容**
**比对权威来源**

文献、数据、史实、引文
逐项回到可靠出处
流畅不等于正确

## 二 审查　使用中

**对进入课堂与评价环节的**
**内容作出判断**

能不能用、用到什么程度
由教师与学校判断
判断权不转移给工具

## 三 留痕　使用后

**记录生成与修改的过程**
**使事后追溯成为可能**

原始材料、加工过程
保存到可回查
追溯是责任的凭据

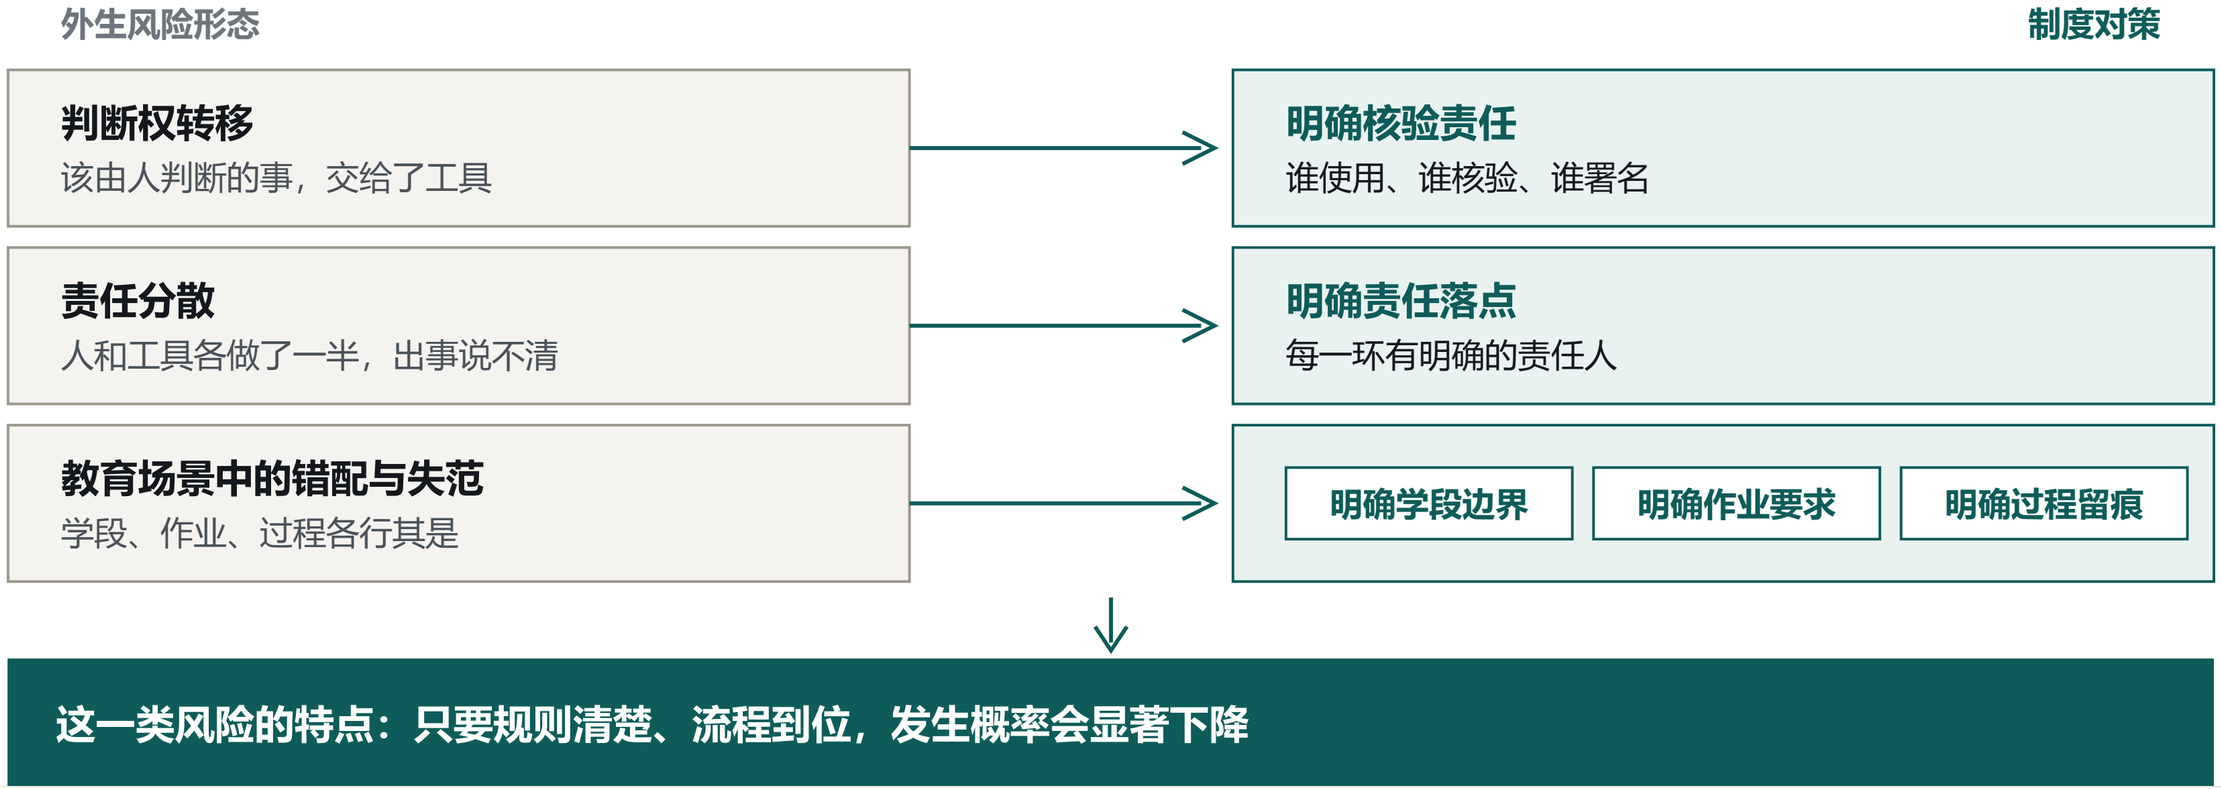
↓

**三个环节的共同点**

**不改变工具的行为，只改变人的工作方式**

**要点**　三个环节都是职业习惯，不是技术动作

# 外生风险靠规则与流程下降，一类风险对应一条制度




**前提** 防范生效的前提，是规则本身存在——下一页处理规则缺失

# 规则缺失不属于使用方式问题，属于制度供给滞后于实践

**三类风险的防范，前提是规则本身存在；现行学校管理制度多形成于生成式人工智能普及之前**

## 缺少明确规定的情形

**其一　作业认定**

**学生作业的作者**
**如何认定**

**其二　教研评比**

**教师用工具生成的材料**
**贡献如何计算**

**其三　信息审批**

**学生信息输入外部工具**
**审批流程如何设置**

**其四　审查归属**

**生成内容进入课堂与评价**
**审查由谁负责**

## 各项的状态

**检测结果作处理依据**

**技术判断已较明确**
缺的是把判断写入制度

**其余各项**

**规则尚未建立**
应对路径与前三类不同

**所以规则缺失须单独处理：它不是使用方式问题，也不是技术机理问题**

**性质**　制度供给滞后于实践，是建立规则的问题，不是纠正用法的问题

# 制度滞后属于新兴技术早期常态，不宜理解为管理疏漏

**研究指出：应用风险构成多层次体系，来源不止技术本身**

清华大学　李焕宏、薛澜的研究

**技术本身**
概率生成机制的固有属性

**人际竞争**
由社会互动引发的冲击

**新旧制度摩擦**
由社会互动引发的冲击

**早期阶段的普遍状态**

**制度滞后于实践，属于常态而非例外**
可行的规制方向，不是等待完备规则

**其一　提升驾驭能力**
提升组织与人员的技术驾驭能力

**其二　同步完善配套**
在实践中同步完善制度配套

**就学校而言：空白期的处理方式尤为关键**

**研究判断**　空白期不是等出来的，是靠能力与配套一起填出来的

# 制度空白之下，处理方式取决于具体经办人的判断

同一情形

**同一位学生**

同一种工具使用

**甲班　认定违规**

经办人理解为违规使用

**乙班　视为正常使用**

经办人理解为正常使用

不同班级、不同学校
可能得到不同结论

**后果一**　**处理不公**

同样的行为，两种截然不同的处理

**后果二**　**规范失去说服力**

规则形同虚设，师生无从遵循

**规范的作用**　**把这类判断从个人裁量，转为共同标准**

共同标准未必一开始就完备，但须先行确立，再在实践中修订——落点在制度，不在个人，与前三类分列

**空白期**　规则可以不完美，但不能没有

# 本部分的结论是三句：风险有来源、可分辨、可控制

## 一 风险有来源

**相当一部分风险来自概率生成机制本身，不是使用不当的偶然结果**

**它改变的是职业要求落实的条件**

**诚实——要求真实的出处**
**公正——要求可核验的依据**
**关爱——要求具体的了解**

概率生成使这三项都更难做到、更难验证

理解这一层，才能理解政策
**走核验与留痕，而非简单禁止**

## 二 风险可分辨

**内生风险与外生风险性质不同，应对方式不同**

一类消不掉，只能改变人的做法；
一类防得住，靠规则与流程

**教师日常遇到具体问题时：**

**先分辨类型**

**再决定处置方式**

分辨先于处置，
处置才不会用错力气

## 三 风险可控制

**内生风险——核验、审查、留痕**
**外生风险——明确要求、调整流程**

两条路径各有落点，
都不要求放弃使用工具

**两类控制都不依赖教师掌握技术细节**

**依赖的是既有职业习惯在新的条件下落实到位**

会教书、会把关，就会控制风险

**三句结论** 有来源，所以不能只怪人；可分辨，所以处置有章法；可控制，所以不必恐惧

# 遇到生成内容出错，先分辨它属于哪一类风险

**操作判断**
**生成内容出错**

- **属于内生风险** → 不必归咎自己使用不当，但必须完成核验
- **属于外生风险** → 检视流程中哪一环缺失，从流程上补足

**混淆两者，会导致两种失误**

| | | |
|---|---|---|
| **失误一** | 把内生风险当作个人过失 | 从而不敢使用工具 |
| **失误二** | 把外生风险当作技术局限 | 从而不去改进做法 |

↓

**这一区分同时说明政策文本的结构（第一部分梳理的各类文件）**

约束条款主要针对外生风险：明确责任主体、明确使用边界、明确审查义务

针对内生风险，文件要求核验与标识，而非禁止使用——技术前提正是两类风险性质不同

**操作结论** 先分辨，再处置：内生完成核验，外生补足流程