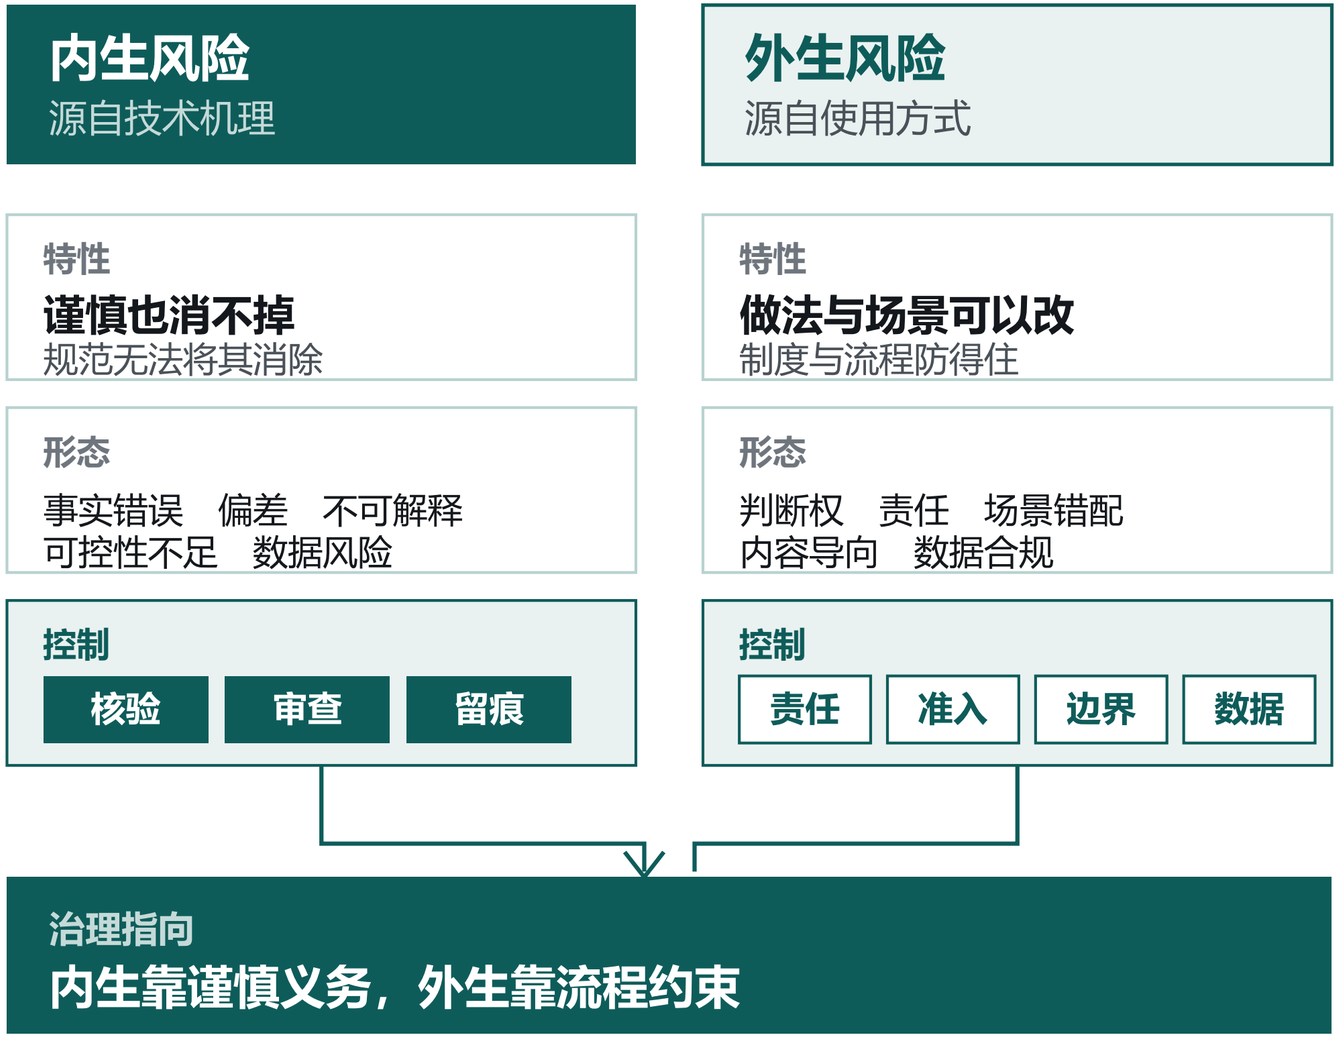
教师人工智能伦理与安全课程　第二部分

人工智能的风险从何而来



目录

01 **概率生成机制及其三个后果**

风险来源须从技术本身界定

02 **源自技术机理的内生风险**

事实错误　偏差　不可解释　可控性与数据

03 **源自使用方式的外生风险**

判断权　责任　场景　内容导向与合规

04 **两类风险的治理指向**

谨慎义务与流程约束

风险来源须从技术本身界定

人工智能的风险，不全是使用不当造成的偶发失误

源自生成机制内部

无论怎样规范都无法消除

不是偶发失误，是机制的正常产物

识别 | 控制 | 留痕

使用不当造成的偶发失误

通过调整做法可以直接避免

与技术机理无关，或仅部分相关

明确要求 | 固定流程

必须谨慎核验的情形

对应左轨：识别、控制与留痕

可以通过调整做法直接避免的情形

对应右轨：把要求与流程定清楚

判断坐标 把风险来源分清，才知道哪里必须核验、哪里可以避免

规范先行于工具普及，因为风险内嵌于技术机制

2025 年 11 月　教育部教师队伍建设专家指导委员会发布
《教师生成式人工智能应用指引（第一版）》

大中小学及幼儿园各级各类教师

正面清单　引导可以做什么

六个方向　三十个场景示例

学习 | 教学 | 育人 | 评价 | 管理 | 研究

提供场景示例，把使用的路先铺出来

约束清单　划定不得逾越的边界

十八个行为示例

事实核查 | **价值审查**

生成内容须经核查与审查，方可使用

定位：引导而非禁止
前提判断：风险有相当部分内嵌于技术机制，须以核验与审查加以控制

前提判断　不能寄望于使用者自然规避，所以规范先行

它不查询数据库、不检索事实，只预测下一个语言单元

1 训练环节

读取海量文本

统计语言单元之间的共现规律

哪个词后面常跟哪个词

何种问句后常接何种回答

这些统计关系被压缩进参数

结果：语言如何组织的概率结构

2 生成环节

依据概率结构逐字输出

每一位置上选择下一个词

依据的是出现可能性最高

接到后面，再预测下一个

如此循环直至形成完整段落

追求表达合理，不保证事实正确

3 对齐环节

在基础模型之上再作微调

加入人工反馈训练

回答更符合人类期待的表达

更愿意正面回应

更少输出有害内容

改的是形式与倾向，不改底层方式

训练完成后，模型掌握的是语言的概率结构，不是世界如何运作的知识体系

三个环节 共同点：概率生成是底层方式，对齐改变不了它

流畅性与正确性已经分离

过去的关联

写作能力与知识水平高度相关

写得通顺、逻辑连贯、术语准确的文字，
多半出自内行之手

概率模型改变了这一关联

学到专业表达的形式，不必掌握内容

句式、术语、论证结构都可以被学到，
形式背后的实际内容不必被掌握

一份学生作业中的表述

根据皮亚杰 1972 年在《认知发展》中提出的第四阶段理论……

句式规范 | 术语正确 | 出处格式标准 | **这本书并不存在，观点也不属于皮亚杰**

结果是一段读起来非常专业的文字，可能包含完全虚构的事实

识别难点 文本没有任何一处读起来别扭，凭阅读经验很难识别

输出不可复现，依据不可追溯

后果二　输出不可复现

生成过程是随机采样

并非只取概率最高的词，
而是在高概率候选集合中
按一定分布抽取

同一问题两次问，答案可能不同

同一份课件，上午与下午生成，
引用数据可能不一致

后果三　依据不可追溯

模型无法给出信息来源

它可以生成一个出处，
那个出处是从统计规律中长出来的，
不是从某本书里查出来的

也说不清推理过程

输出不经过逐步论证，
而是整体分布下的连续采样

限定　训练数据决定边界

能力覆盖约等于语料覆盖

语料未含　无法可靠输出

语料偏差　继承并在场景中放大

截止点后　无从知晓

近两年政策文件可能已过时，
地方性规定可能给的是别省做法

教师要向家长解释判断依据、向教研组说明材料出处，工具给不了这一层支撑

三个后果　流畅不等于正确，答案不同不等于哪次错了

内生风险不因使用方式改变

内生风险：由技术机理直接产生，无论使用者如何谨慎都会存在
不能通过规范消除，只能通过核验、审查与留痕加以控制

其一　事实性错误　发生频率最高的一类，表现为四种形态

编造文献

作者、期刊、年份、卷期、页码俱全，
十条文献中三条查无此文、两条作者错配

未逐条核查即写入申报书，性质属于学术不端

混淆事实

年代、人物、事件因果容易错位，
整体框架合理、局部细节错误，读起来顺畅

中唐诗人置于盛唐，变法归入唐代

虚构引文

张冠李戴的名句与后人伪托之诗

数据失当

逻辑自洽而物理上不成立

发生频率最高　四种形态的共同点：读起来毫无破绽

这类错误不是工具出错，是工具正常工作的产物

虚构引文

一句被标注为苏轼的话，实际出自明清笔记

一首被标为杜甫所作的诗，实际是后人伪托

工具甚至能为伪作生成一套自洽的赏析，
解释其创作背景与艺术特色

名句赏析最难识别：它附带看似权威的出处

数据失当

生成的物理题，条件设置导致方程无解

生成的化学方程式，配平错误

生成的数据表，各列数据与说明文字不符

生成的统计图，百分比之和超过一百

共同点：逻辑自洽，而物理上不成立

这一行为模式在技术上被称为幻觉

在缺乏可靠依据时，它依据统计规律生成一个看起来最像答案的表述，而不是承认不知道

更准确的表述
它没有区分知道与不知道的机制

不是故障 模型的任务是生成最可能的表述，不是核实事实

偏差以客观数据的面目出现

训练数据
历史文本中呈现的世界

→

模型学习
结构性倾向被继承下来

→

判断类任务
在评价与分层中稳定复现

评价场景　作文评分

训练数据来自历年高分作文，
某种特定文风与题材被视为高分特征

引古诗多　判为高分

口语化叙述　判为低分

依据是训练数据中的统计关联，
不是该篇作文的实际水平

推荐与分层场景　系统性不利

对特定群体的不利不是偶然，
而是每次判断都朝同一个方向偏

某类学生答题数据被更频繁地标记为异常

其学习轨迹被更早判定为需要干预，
资源与期待随之改变

隐蔽性：不表现为明显的不公平，而表现为客观数据得出的结果

警惕点　使用者不加辨析，容易将其视为中立判断

输出给不出可核查的推理路径，申诉就无法展开

其三　不可解释性

参数达到千亿量级之后，
技术人员也无法完整解释某一次输出

学生被告知作业存在抄袭
家长询问依据，学校给不出具体的比对过程

平台建议该生进入基础班
教师询问判断标准，平台以商业秘密为由不予说明

其四　可控性不足

模型的输出可被诱导突破预设限制

提示注入
输入中嵌入指令，忽略原有设定

越狱
特定表述绕过内容过滤

对教师的影响不在恶意攻击，而在稳定性：
同一份系统提示下，一次措辞变化的输入，
就可能使输出偏离预期

用于班级管理的自动化助手，可能因学生一句特殊问法而输出不当内容，
而这一情形在测试阶段并未出现

申诉的前提　当事人能知晓自己被如何判断，否则无法有效申诉

评分算法被撤回，因为当事人无从知晓自己被如何判定

2020 年 8 月上旬

成绩由模型批量生成

取代因疫情取消的考试，
依据学校历年成绩记录推算分数

算法细节未向公众披露

学生与教师无申诉通道

8 月 13 日　成绩公布

大量学生分数低于教师预估

英格兰地区高考与会考成绩
由第三方机器学习模型批量给出

抗议迅速蔓延

分数由算法决定，却无从质询

8 月 17 日　宣布放弃

放弃算法调整

考试监管机构宣布
改用教师预估成绩

教育大臣公开道歉

评分算法被整体撤回

撤回的原因不是技术错误

是当事人无从知晓自己被如何判定，也无法就此提出异议

案例落点　不可解释且无申诉通道，算法就只能被撤回

数据风险有两个方向：来路与去向

其五之一　训练数据方向　内容的来路

语料中可能包含

- 个人信息
- 受著作权保护的作品
- 未公开的内部材料

使用者无法从输出端判断：
某个具体表述是否源自受保护的内容

- 课件中的图片、文案　存在侵权可能
- 学生作业中的段落　可能与他人作品高度重合

其五之二　交互数据方向　材料的去向

用户与工具的对话内容

- 是否留存　是否用于后续训练　存于何处　保留多久

取决于服务条款，不取决于用户意愿

教师将学生材料输入工具后，
这些材料进入服务方的数据处理流程

- 教育机构失去了对材料流转的控制

一个看来路：内容是否干净　一个看去向：材料是否失控

两个方向　训练数据决定内容来路，交互数据决定材料去向

信息一旦离开教育机构，流转即不再受机构控制

2021 年起　组建招生团队

以教育咨询公司与航空服务公司名义
向他人购买或交换获取学生信息
用于电话招生

多次将信息出售、提供给第三方

吴某甲、吴某乙兄弟

2024 年 3 月　非法提供

7631

条学生信息

向他人非法提供，
信息从机构流出后层层转手

2024 年 5 月　警方查处

1557124

条　去重后查获

从电脑、手机中查获
公民个人信息

温江法院审理认定：侵犯公民个人信息罪，情节特别严重
各判处有期徒刑三年，并处罚金二万元

案件启示　信息一旦离开教育机构，其流转即不再受机构控制

外生风险可由制度约束防范

外生风险：与技术机理无关或仅部分相关，取决于使用者的做法与场景条件
可以通过明确要求、调整流程加以防范　教育领域现行规范的主体部分针对的正是这一类

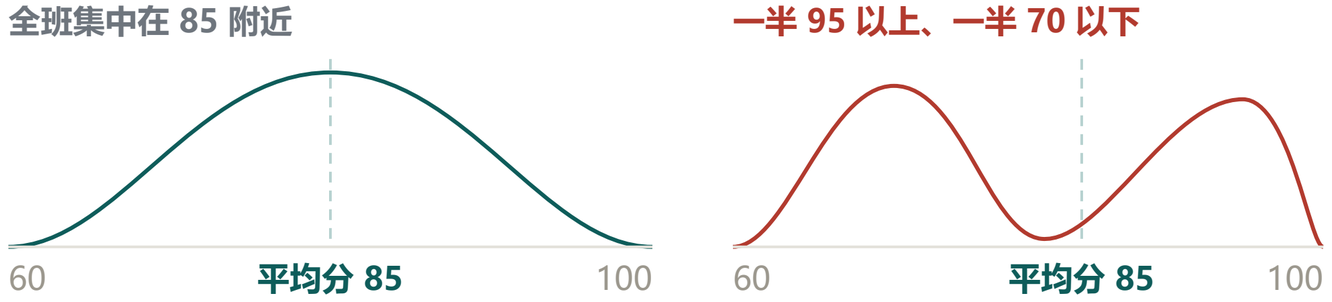
其一　判断权转移

工具承担生成，教师承担判断

分工容易被打破，
因为工具的输出看起来
已经完成了判断

学情分析中的表现

同一个平均分 85，教学需要看的是分布



成绩表是原始材料，分析报告是加工结论，中间那一步判断必须由教师完成

模板化输出与完整答案，取消的正是教育功能

学生评语中的表现

期末评语批量生成，一个班四十余份

单看　每一份都通顺得体

比对　句式结构高度一致

开头句式、段落结构、鼓励用语高度一致，
甚至副词的使用频率都相近

家长会上当场比对相邻两名学生的评语，
除姓名与个别细节外内容雷同

答疑环节中的表现

工具生成答案后原样转发

知识上多半正确，两种失当：

一　解答方式超出学生当前学段
用微积分解初中函数问题，学生看不懂

二　绕开了学生真正卡住的那一步
学生得到完整解法，仍然不知道自己错在哪里

评语的功能是让学生感到被具体地看见，答疑的价值是定位卡点

共同问题　完整答案恰恰跳过了定位卡点这一步

责任归属取决于署名与实施，不取决于用了什么工具

技术提供者 → 平台运营方 → 学校 → **教师**

教研协作中的表现

备课组共同使用平台生成单元教学设计，
材料进入课堂后发现史料引证有误，
追溯时无人明确该份材料由谁审核

集体使用不构成免责
授课教师对本班教学内容承担责任

学校采购系统后的表现

作业批改系统评分直接计入平时成绩，
学生提出评分有误，教师答「系统算的」，
学校答「由平台负责」

这一答复在制度上不成立
学校作为使用方，对系统输出结果承担责任

工程图纸由软件绘制
签字的设计师承担责任

会计凭证由系统生成
签章的会计承担责任

责任落点　工具的介入不改变责任的落点，只改变作业的方式

署名者承担核查义务，工具不承担任何责任

2026 年　论文被质疑

安徽财经大学法学院教师蒋某某与学生万某某
联合发表的学术论文，被媒体质疑注释编造

问题出在对智能检索结果的误信

调查组认定

五名校内外专家组成调查组
对生成内容缺乏应有的警惕性与严谨性，
存在使用不当行为

同年 9 月 2 日　学校通报处理结果

- **科研诚信诫勉谈话**
- **通报批评**
- **暂停评先评优、晋升、科研奖励两年**

核查义务落在署名者身上，工具不承担任何责任

责任确认　对生成内容缺乏警惕与严谨，就是责任的落点

认知负荷落在哪里，决定工具是风险还是资源

其三　教育场景风险　第一种情形：学段能力与工具能力错配

四年级动物作业的教训

工具给出的材料中混入了
已被学界否定的分类说法，
作业格式规范、语句通顺，
知识是错的，学生无从识别

小学　不具备真伪判断能力

独立使用开放式生成，
得到的内容会整体接受

格式规范、语句通顺、知识是错的

初中　初步的逻辑检验能力

可以承担分析比较类任务：
让工具生成两种对立观点，
再找出各自论证的漏洞

认知负荷落在鉴别上

工具的错误反而成为教学资源

高中　可进入原理层面

测试同一问题
在不同提示方式下的输出差异，
从而理解概率生成机制的局限

错误成为理解机制的入口

输出差异本身就是教材

从会用工具到理解工具的边界

学段不同　同一个工具，风险性质就不同

检测与追查都靠不住，留痕与真实交往才靠得住

学术诚信边界模糊

读后感：情感饱满、结构完整、引用得当，
教师怀疑由工具生成，但无法举证

事后追查基本无效

输出无固定特征可比对，
检测工具准确率不足以作处分依据

可行路径是事前设计

提纲草稿、修改痕迹、资料出处，以过程性材料判断投入

师生关系与情感支持被替代

学生遇同伴矛盾、家庭冲突、升学焦虑，
转向工具倾诉

不会不耐烦　不会评价　随时可用

回应结构完整、情感中立、与处境缺少实质关联，
但即时且无条件，往往被认为比谁都懂我

工具给情绪安抚，不给教育性陪伴

社会性发展依赖真实交往：被误解、需解释、要妥协

实验课要求提交原始数据记录而非仅提交结论报告　记录本身构成学习证据

识别途径　班主任留意学生表达方式与交往状态的变化

作业成绩体现的是工具能力，不是学生自己的思考能力

回顾性研究

26811

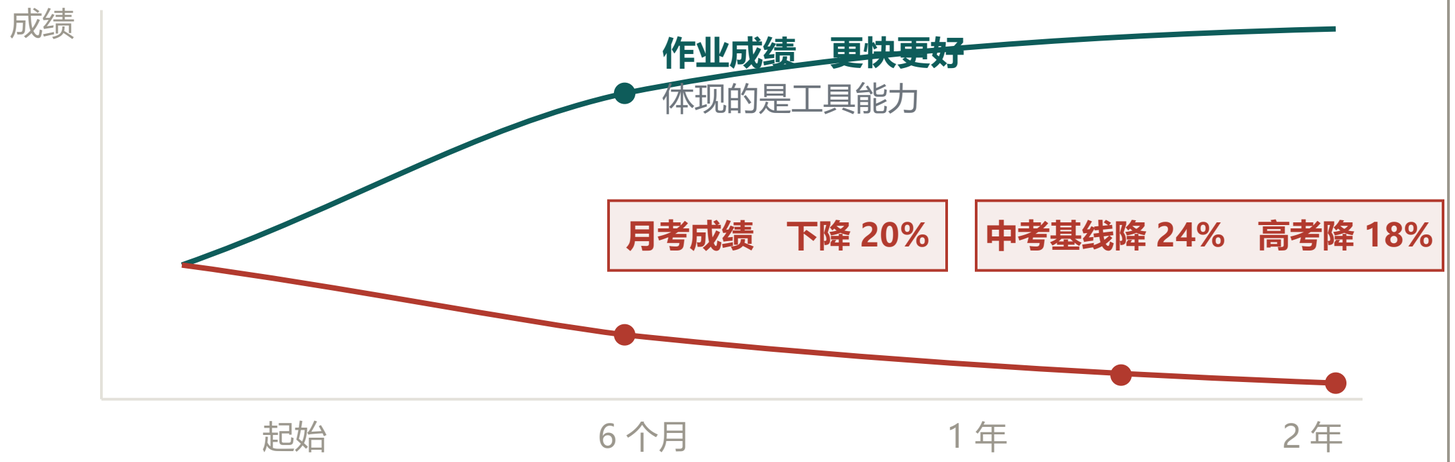
名初高中学生

我国中部某县 9 所中学
跨度 30 个月的学业记录

使用智能工具完成作业之后

香港大学经济学教授吴延晖牵头

作业成绩与考试成绩，向两个方向分开



作业完成质量已不足以反映实际投入　过程性材料因此必要

研究判断　作业成绩越好，越不能证明学生的思考能力在增长

分层依据不公开，差距就被机制化放大

算法分层机制

正确率与答题时长 → 自动分层 → 推送不同难度内容

失效点一　分层依据不向学生与家长公开

学生无从知晓自己为何被归入某一层，也无从申诉

失效点二　分层结果一旦固化

低层级学生获得的资源、期待与自我认知同步下降，差距被机制化放大

其四　内容与价值导向风险

共同特征：错误内容看起来不像错误

通顺、连贯、结构完整，
甚至附带看似权威的出处

历史与地理素材

- 地图边界画法错误　政治性问题
- 历史叙述分期、因果、民族关系偏差
- 人物图像服饰器物与史实不符

政策强调保障自主决策权　落点正在于分层依据须可查询、可申诉、可调整

其四　内容与价值导向　课件插图被学生当作信史接受，纠正成本远高于教学成本

分层标准是否公开，是争议的共同焦点

2026 年秋季学期
武汉多所初中在阳光分班基础上推行分层走班

学校的做法

汉阳三初

11 月期中考试后，依据期中成绩对数学、英语分层，学生按成绩进入三个层级，由不同师资团队授课

- 拔高
- 提升
- 基础

二桥中学

两校区已启动数学周测，分层细则待公布

同期杭州、济南等地

家长公开争论

分层依据与资源配置，部分学校被要求说明分层标准

按什么分?

成绩之外还看什么

依据是否公开?

学生与家长能否查到

资源是否跟进?

分层后师资与资源同步吗

三问 争议集中于按什么分、依据是否公开、资源是否同步

错误内容看起来不像错误

通顺、连贯、结构完整，甚至附带看似权威的出处

文献与文学素材

古诗赏析朝代混淆、作者错配
引文标注看似规范，出处不存在
名人名言归属错误

最难识别
教师通常没有时间逐条核对原书

科学素材

例题数据设置导致无解
化学方程式配平错误
图表与文字说明不一致，流程缺环节

直接进入知识结构
学生以错误前提继续推理

价值导向方面

民族、宗教、领土主权等议题上，
生成内容可能出现表述偏差

不属于教学疏忽
属于未履行审查义务

其五　数据合规风险

学生名册、成绩表、家庭情况说明、心理健康记录、身份信息，均属个人信息，部分属敏感个人信息

其五　数据合规　将其输入外部服务，等同于把信息转移给第三方

图省事、没意识、随意选工具，合规就在这些地方失守

情形一　图省事

为分析成绩，上传完整成绩表

连同姓名、学号一并上传，
而分析所需仅是分数一列

最小必要原则被越过

**全班身份信息与成绩信息
同时进入外部服务**

情形二　无意识

班级群内上传学生活动照片

用工具生成活动集锦，
照片中的面部信息已被处理

监护人未作单独授权

**入学告知书中的概括条款
不构成对肖像、音视频的单独授权**

情形三　工具选择随意

用来源不明的免费工具

处理学生材料，数据存储于
境外服务器，出境未履行程序

服务条款保留了训练使用权

**学生材料因此进入训练语料
永久留存于模型之中**

三种情形的共同后果：材料进入第三方处理流程，机构失去流转控制

合规底线　输入外部服务之前，先问材料该不该出去、出去多少

内生风险靠谨慎义务，外生风险靠流程约束

内生风险　无法通过规范消除		外生风险　制度约束可以防范	
使用前	核验　对事实性内容逐项比对权威来源	责任	明确谁审核、谁署名、谁承担
使用中	审查　评价、分层、价值导向由人复核	准入	明确工具准入的标准与程序
使用后	留痕　保留原始材料与加工过程	边界	明确学生使用的边界与记录方式
这是谨慎义务，不是禁止使用		明确数据处理的规范 第一部分已涉及，第三部分落为可执行的要求	

治理指向　两条路径都不要求教师放弃使用工具

治理强度随风险可否被规范消除而分档

2026 年　《北京市教育领域人工智能应用指南》
高等教育领域　覆盖教学、科研、管理等七类场景

禁止准入

需要体现以下能力的场景，
人工智能不得介入

独立学术能力　独立思考能力
专业判断力　伦理思辨力

有限使用

机理层面无法消除的风险，
以有限使用加以约束

内生风险的治理档位

鼓励使用

使用方式层面的风险，
以鼓励使用加流程要求规范

外生风险的治理档位

与两类风险的区分同构

机理层面无法消除的风险，
以禁止准入与有限使用加以约束

使用方式层面的风险

以鼓励使用加流程要求加以规范，
治理强度随风险可否被规范消除而分档

同构关系　机理管不了的用准入管，使用层面的用流程管

工具扩展作业能力，不替代专业判断

对内生风险
不指望工具可靠，只保证核验到位

对外生风险
不依赖个人谨慎，只依靠流程约束

保持对工具的准确定位
作业能力的扩展，不是专业判断的替代

分清风险来源
内生消不掉，外生防得住

核验与留痕
使用前核验，使用后留痕

流程约束
责任、准入、边界、数据定清楚

技术改变的是完成工作的方式，未改变对工作结果的责任

收口 工具越快，判断越要慢；生成越容易，核验越不能省